

机器学习与量子多体问题


第一部分

量子自旋问题

从张量网络到神经网络

何力新

中国科学技术大学



还原论与层展论

两种互补的视角：追溯基本规律，理解集体行为

还原论

Reductionism

分解系统，研究组分
寻找微观的基本规律

生物


生命活动与整体功能

分子

化学键与分子结构

原子

原子核与电子



层展论

Emergence (涌现)

研究组分的关联
理解整体的集体行为

微观规律始终成立，新的尺度需要新的概念与描述。

More is different (多者异也)


P. W. Anderson, 1972

多体系统能够形成单个粒子所不具有的物态




超导

电流可以无电阻地流动



玻色-爱因斯坦凝聚

极低温下，大量粒子
占据同一量子态



Kagome晶格示意

量子自旋液体

没有长程磁序
仍有强量子关联

理解多体系统，需要研究粒子之间的关联和整体的组织方式

自旋的方向与本征态

自旋 $\frac{1}{2}$: 沿选定方向的自旋分量, 有两个本征态。

自旋指向 n 方向



箭头表示自旋平均值的方向

沿 n 方向测量, 确定得到 $+\hbar/2$

沿 z 方向的两个本征态



$|\uparrow\rangle$

自旋向上

$$S_z |\uparrow\rangle = +\frac{\hbar}{2} |\uparrow\rangle$$



$|\downarrow\rangle$

自旋向下

$$S_z |\downarrow\rangle = -\frac{\hbar}{2} |\downarrow\rangle$$

本征态: 测量对应的物理量, 结果确定。

选定 z 方向后, 用 $|\uparrow\rangle$ 和 $|\downarrow\rangle$ 作为描述自旋态的一组基底。

从一个自旋到多个自旋

对自旋 $\frac{1}{2}$ 系统，每增加一个自旋，基底态的数量就翻一倍。

2 个自旋

$|\uparrow\uparrow\rangle$

$|\uparrow\downarrow\rangle$

$|\downarrow\uparrow\rangle$

$|\downarrow\downarrow\rangle$

$\times 2$
→

3 个自旋

$|\uparrow\uparrow\uparrow\rangle$

$|\uparrow\uparrow\downarrow\rangle$

$|\uparrow\downarrow\uparrow\rangle$

$|\uparrow\downarrow\downarrow\rangle$

$|\downarrow\uparrow\uparrow\rangle$

$|\downarrow\uparrow\downarrow\rangle$

$|\downarrow\downarrow\uparrow\rangle$

$|\downarrow\downarrow\downarrow\rangle$

$\times 2$
→

4 个自旋

$|\uparrow\uparrow\uparrow\uparrow\rangle$

$|\uparrow\uparrow\uparrow\downarrow\rangle$

$|\uparrow\uparrow\downarrow\uparrow\rangle$

$|\uparrow\uparrow\downarrow\downarrow\rangle$

$|\uparrow\downarrow\uparrow\uparrow\rangle$

$|\uparrow\downarrow\uparrow\downarrow\rangle$

$|\uparrow\downarrow\downarrow\uparrow\rangle$

$|\uparrow\downarrow\downarrow\downarrow\rangle$

$|\downarrow\uparrow\uparrow\uparrow\rangle$

$|\downarrow\uparrow\uparrow\downarrow\rangle$

$|\downarrow\uparrow\downarrow\uparrow\rangle$

$|\downarrow\uparrow\downarrow\downarrow\rangle$

$|\downarrow\downarrow\uparrow\uparrow\rangle$

$|\downarrow\downarrow\uparrow\downarrow\rangle$

$|\downarrow\downarrow\downarrow\uparrow\rangle$

$|\downarrow\downarrow\downarrow\downarrow\rangle$

$$2^2 = 4$$

$$2^3 = 8$$

$$2^4 = 16$$


每个 $|\dots\rangle$ 表示一个自旋构型，对应一个直积基底态。

N 个自旋: $2 \times 2 \times \dots \times 2 = 2^N$ 个基底态

Heisenberg 模型：自旋之间的相互作用

哈密顿量 H 是能量算符，描述相邻自旋之间的交换作用。

一维近邻自旋链



$$H = J \sum_{i=1}^{N-1} \mathbf{S}_i \cdot \mathbf{S}_{i+1}$$

S_i : 第 i 个位置的自旋算符

J : 交换耦合，符号决定偏好

取 $\hbar = 1$

$J < 0$ 铁磁耦合



经典图像：同向更有利

$J > 0$ 反铁磁耦合




经典图像：反向更有利

整个系统的相互作用，是所有近邻键上局部耦合的总和。


基态与变分法

寻找能量最低的量子态，是理解低温物性的起点。

能量最低的本征态



变分法：调整试探态，降低能量



试探态的能量给出 E_0 的上界，近似精度取决于试探态与优化。

两个自旋：量子叠加能进一步降低能量

$$H = J S_1 \cdot S_2, J > 0 \text{ (反铁磁)}, \hbar = 1$$

固定的反向构型



$$|\uparrow\downarrow\rangle$$

$|\downarrow\uparrow\rangle$ 的能量相同

能量期望

$$-J/4$$

量子叠加形成基态



$$|\psi_0\rangle = \frac{|\uparrow\downarrow\rangle - |\downarrow\uparrow\rangle}{\sqrt{2}}$$

基态能量

$$E_0 = -3J/4$$

若只是以各 50% 的概率随机选取两种构型，平均能量仍为 $-J/4$ 。


负号表示相对相位，量子叠加包含经典概率之外的信息。

经典构型与量子叠加

经典微观态对应一个确定构型，量子态可以是多个构型的相干叠加。

经典：一个确定构型

每个自旋的方向都已确定



N 个自旋方向

描述一个构型的规模随 N 线性增长

求基态：经典优化自旋方向，量子优化整个波函数。

量子：多个构型的叠加

同一组自旋的不同构型

$$|\Psi\rangle = c_1 \left| \begin{array}{cccc} \uparrow & \downarrow & \uparrow & \downarrow \end{array} \right\rangle + c_2 \left| \begin{array}{cccc} \uparrow & \downarrow & \downarrow & \uparrow \end{array} \right\rangle + c_3 \left| \begin{array}{cccc} \downarrow & \uparrow & \uparrow & \downarrow \end{array} \right\rangle + \dots$$

一般需要 2^N 个振幅

振幅 c_1 、 c_2 、 c_3 ... 还包含相对相位

蒙特卡洛：用随机采样求解自旋模型

从大量配置中按统计权重抽样，估计能量、磁性和关联。

经典蒙特卡洛 (MC)

采样对象：一组确定的自旋方向




$$p(C) \propto \exp\left[-\frac{\Delta E(C)}{k_B T}\right]$$

按能量变化接受或拒绝更新
温度越低，越偏重低能构型

量子蒙特卡洛 (QMC)

采样对象：构型及其间的量子跃迁



非负权重时：

$$P(C) \propto W(C)$$

权重由量子哈密顿量决定

权重有正负号时，可能出现符号问题

共同思路：采样、求平均；QMC 可在足够低温下研究基态性质。

自旋阻挫：局部最优无法同时满足

先看经典自旋：反铁磁耦合 $J > 0$ ，希望每条键上的两个自旋都反向。

一条键：可以满足

反向排列使这条键能量最低




反向 180°

单条键的最优条件可以实现

三角形：出现冲突

先尝试把自旋上下交错排列




有一条键无法反向

翻转右下自旋，冲突转移

连续转动：作出折中

三个自旋寻找整体最优排列



方向两两相差 120°


各键折中，使总能量最低

阻挫：各条键的最低能量条件，无法在同一个构型中同时实现。

阻挫晶格：三角格子与 Kagome

每个圆点代表一个自旋，所有连线都取反铁磁耦合 $J > 0$ 。


三角格子



三角形共享一条边

内部的每个自旋连接 6 个最近邻

Kagome 格子



三角形共享一个顶点

内部的每个自旋连接 4 个最近邻

每个自旋同时参与多个三角形，基态需要协调整个晶格中的相互作用。


J_1 - J_2 模型：正方格子也会阻挫

先用经典方向图像看竞争： J_1 与 J_2 都希望相连自旋反向。

$$H = J_1 \sum_{\text{最近邻}} \mathbf{s}_i \cdot \mathbf{s}_j + J_2 \sum_{\text{次近邻}} \mathbf{s}_i \cdot \mathbf{s}_j$$


$$J_1 > 0, J_2 > 0$$

两类反铁磁耦合




J_1 : 最近邻
 J_2 : 对角线上的次近邻

Néel 排列



J_1 : 全部反向
 J_2 : 全部同向

条纹排列



J_2 : 全部反向
 J_1 : 一半同向


两种相互作用竞争时，真正的量子基态会是什么？

量子自旋液体

即使在零温，仍无常规长程磁序，却保留非平凡的多体纠缠。

磁有序

规则的自旋关联延伸到远处




出现稳定的长程排列模式

图中以 Néel 反铁磁序为例


量子自旋液体

共振价键（RVB）图像：多种配对的叠加

配对方式 A



配对方式 B



+

+ ...

$$|\Psi\rangle = c_1|A\rangle + c_2|B\rangle + \dots$$

●—● 单态：一对自旋组成的纠缠态

“液体”指自旋的集体状态。仅凭无磁序，还不足以确认自旋液体。


量子自旋液体 (Quantum Spin Liquid)

量子涨落中的有序。
——另一种量子世界

1 图像与直观理解

在无序中孕育量子关联

受挫的自旋体系 (以三角晶格为例)



三角晶格中的受挫自旋 (示意图)

几何阻挫

三角晶格中自旋间相互作用无法同时满足, 导致强烈的几何阻挫 (frustration)。


强量子涨落

自旋方向持续量子涨落, 没有静止的有序排列。

无长程磁有序

即使在极低温下, 也不形成常规的铁磁或反铁磁长程有序。

共振价键 (RVB) 图像



自旋以单重态 (自旋对) 形式在不同的键构型之间量子叠加和共振, 形成动态的“共振价键 (RVB)”态。

共振价键 (RVB)

单重态键在不同配对方式之间不断涨落, 形成没有固定图案的量子液体。

不是静止的排列,
而是动态的量子流动!

2 主要物理性质

超越传统磁有序的新奇性质

1 无自发对称性破缺

低温下仍不形成常规磁有序, 保持对称性 (如 $SU(2)$ 自旋旋转对称性)。



无长程磁有序

2 长程量子纠缠


基态具有非局域关联, 量子纠缠在长距离上仍然存在。



非局域量子纠缠

3 分数化激发


可出现自旋子 (spinon) 等携带分数化量子数的准粒子。



自旋子激发 (示意)

4 拓扑性质


可能具有拓扑序、地面态简并, 以及非常规的边界态 (如边缘自旋子)。



拓扑序与边界态

5 异常响应

在热输运、散射谱、比热、磁化率等方面表现出非常规的行为。



3 为什么重要

从基础科学到未来应用



理解强关联量子物态的新范式

为理解强关联电子体系中的新奇量子物态提供了重要的理论框架和实验平台。



拓扑序与量子纠缠研究的重要平台

是研究拓扑序、长程量子纠缠、以及新奇量子激发的理想平台。



与高温超导、受阻挫磁体等问题密切相关

为理解高温超导机理、受阻挫磁体中的奇异行为等重要问题提供了新的思路。



为容错量子计算和拓扑量子信息提供启发

其拓扑性质和分数化激发 (如任意子) 为实现容错量子计算和拓扑量子信息处理提供了重要的物理启发。

量子自旋液体是凝聚态物理中, 最具挑战性和吸引力的量子态之一。



核心特征


量子自旋液体是在零温附近仍保持量子涨落、没有传统磁有序、却具有长程纠缠与新奇激发的量子多体态。

对 N 个自旋态做精确对角化 (Exact Diagonalization)

1. 定义物理模型

以自旋-1/2 海森堡模型为例：

$$H = J \sum_{\langle i,j \rangle} \mathbf{S}_i \cdot \mathbf{S}_j + h \sum_i S_i^z$$



N 个自旋-1/2,
每个自旋有两个态
 $|\uparrow\rangle, |\downarrow\rangle$,
总的希尔伯特空间维度为
 $D = 2^N$ 。

2. 构造基态

采用计算基

$$|\sigma_1 \sigma_2 \cdots \sigma_N\rangle$$

$(\sigma_i = \uparrow, \downarrow)$ 。

$$\begin{bmatrix} |\uparrow \uparrow \cdots \uparrow\rangle \\ |\uparrow \uparrow \cdots \downarrow\rangle \\ |\uparrow \downarrow \cdots \uparrow\rangle \\ \vdots \\ \dots \\ |\downarrow \downarrow \cdots \downarrow\rangle \end{bmatrix}$$

基态总数： $D = 2^N$

3. 构造哈密顿矩阵

在基态下计算矩阵元

$$H_{ij} = \langle i | H | j \rangle,$$

得到一个 $D \times D$ 的
厄米矩阵 H 。

$$H = \begin{bmatrix} H_{11} & H_{12} & \cdots & H_{1D} \\ H_{21} & H_{22} & \cdots & H_{2D} \\ \vdots & \vdots & \ddots & \vdots \\ H_{D1} & H_{D2} & \cdots & H_{DD} \end{bmatrix}$$

4. 精确对角化

求解本征值问题


$$H|\psi_n\rangle = E_n|\psi_n\rangle$$

使用线性代数算法
(如 LAPACK) 对矩阵 H
进行对角化。

得到所有本征值 $\{E_n\}$
和本征态 $\{|\psi_n\rangle\}$

5. 结果分析

能谱 (示例)



- 能量谱
- 基态性质
- 关联函数
- 相变与物理量的计算
- ...

为什么难：波函数的指数规模

直接计算量子态的全部振幅，所需存储量随自旋数指数增长。

只存一个波函数，需要多少空间？

自旋数 N	振幅数 (约)	存储量 (约)
20	1.05×10^6	16.8 MB
30	1.07×10^9	17.2 GB
40	1.10×10^{12}	17.6 TB
50	1.13×10^{15}	18.0 PB

按每个复振幅 16 字节估算，单位采用十进制。

增加 10 个自旋

存储量变为原来的

$\times 1024$

表中只算一个波函数，
还未计入求解时的额外空间。

突破口：利用物理结构，寻找更紧凑的表示与更有效的计算方法。

精确对角化与量子蒙特卡洛

两种计算思路：直接求解本征态，或通过随机采样估计物理量。

比较项	ED：精确对角化	QMC：量子蒙特卡洛
核心思路	在所选状态空间中 直接求最低本征态	将物理量写成配置求和 通过随机采样估计
主要优势	小系统的高精度基准 可检验其他近似方法	无符号问题中 可研究较大系统
主要瓶颈	状态空间随 N 指数增长 存储和计算量迅速增加	阻挫时可能有符号问题 正负抵消使统计误差难控制

强阻挫问题中，如何兼顾计算规模与结果精度？

机器学习与量子多体问题

第二部分

张量网络方法

如何有效地表示一个多体波函数？


何力新

中国科学技术大学

一维 MPS




二维 PEPS



一维自旋链与多体波函数


每个自旋对应一个指标，所有构型的振幅组成一个高阶张量。

四个自旋的位置



$s_i \in \{\uparrow, \downarrow\}$ 每个指标有两个取值

波函数的系数：四阶张量



$2 \times 2 \times 2 \times 2 = 16$ 个振幅


$$|\psi\rangle = \sum_{s_1, s_2, s_3, s_4} C_{s_1 s_2 s_3 s_4} |s_1 s_2 s_3 s_4\rangle$$

N 个自旋对应 N 阶系数张量，仍有 2^N 个振幅。此时还没有压缩。

从 SVD 到 MPS

把完整波函数逐步分解为局部张量，最终形成一条相连的链。


完整系数张量



先整理成矩阵

s_1 一组，其余自旋一组


分出第一个自旋



一次 SVD 分成两部分

$$M = U \Sigma V^\dagger$$

依次向右分解




重复分解余下部分

得到 MPS

SVD 逐次分出一个局部张量，重复这一过程，就得到 MPS。

截断 SVD：用两个小矩阵近似一个大矩阵

保留主要奇异值，将权重吸收到两个因子中



$$A \approx BC^\dagger, \quad M \ll \min(N_1, N_2)$$

$$\text{存储量: } N_1 N_2 \rightarrow M(N_1 + N_2)$$


保留 M 个主要模式；奇异值的权重已吸收到 B 、 C 中。

奇异值衰减越快，越有可能用较小的 M 获得高精度近似。

MPS 怎样表示与压缩波函数

A_i 是第 i 个位置的局部张量，其元素是待优化的参数。

$A_i^{s_i}(l, r)$ ：固定 s_i 后的矩阵， l 为行、 r 为列，对应左、右连接。



MPS ansatz

(开边界)

$$|\Psi\rangle = \sum_s A_1^{s_1} A_2^{s_2} \cdots A_N^{s_N} |s\rangle$$

截断：保留较大的奇异值

键维数 D 控制参数量与精度

$$2^N \xrightarrow{\text{存储参数量}} O(ND^2)$$


能否有效压缩，取决于目标态能否用较小的 D 达到所需精度。

二维张量网络：PEPS


二维格子内部的 A_i 是位置 i 的局部张量，其元素是待优化的参数。

$A_i^{s_i}(l, u, r, d)$ ：固定 s_i 后的四阶张量，指标依次对应左、上、右、下。

一维 MPS：左右连接



二维 PEPS：上下左右连接



PEPS ansatz


$$|\psi\rangle = \sum_s \text{tTr}[A_1^{s_1} A_2^{s_2} \cdots A_N^{s_N}] |s\rangle$$

tTr 表示沿二维网络收缩所有内部指标，得到每个自旋构型的振幅。

纠缠面积律与 PEPS

许多局域系统的基态，纠缠熵主要随区域的边界大小增长。

区域 A 与外部 B



纠缠熵 $S(A)$

衡量区域 A 与外部的量子纠缠

二维中的“面积”就是边界长度

PEPS 的纠缠受到跨界连接的限制

$$S(A) \leq n \log D$$

n : 穿过边界的连接数

D : 每条连接的维数

PEPS 的局部连接结构与面积律相符，为紧凑表示这类基态提供了物理依据。


蒙特卡洛采样与变分优化

把所有 A 的元素记为参数 θ ，以降低能量为目标调整波函数。

目标：最小化能量

$$E(\theta) = \frac{\langle \psi(\theta) | H | \psi(\theta) \rangle}{\langle \psi(\theta) | \psi(\theta) \rangle}$$

蒙特卡洛采样

$$p(s) \propto |\psi(s)|^2$$



估计能量与梯度

由样本估计

$$E(\theta), \nabla E(\theta)$$

能量和变化方向

更新张量参数



按梯度调整 A 的元素

用更新后的波函数继续采样

通过反复采样与优化，在选定的张量网络中寻找低能态。

能量的蒙特卡洛估计


从 $p(s) \propto |\psi(s)|^2$ 抽取构型，用样本平均估计能量。

$$E = \sum_s p(s) E_{\text{loc}}(s) \approx \frac{1}{M} \sum_{k=1}^M E_{\text{loc}}(s^{(k)})$$

对全部构型加权求和

M 个样本的平均

抽到的构型



局部能量

$$E_{\text{loc}}(s) = \frac{(H\psi)(s)}{\psi(s)}$$

H 作用后的振幅 ÷ 原振幅


按 $p(s)$ 抽样后，直接对局部能量取平均，即可估计能量。

J_1 - J_2 模型：竞争中的量子基态

以自旋 1/2 的正方格子模型，检验 PEPS 对强阻挫基态的描述。

$$H = J_1 \sum_{\text{最近邻}} S_i \cdot S_j + J_2 \sum_{\text{次近邻}} S_i \cdot S_j \quad J_1 > 0, J_2 > 0$$

两类反铁磁耦合



— J_1 : 最近邻

--- J_2 : 对角耦合

强竞争区域

$$J_2/J_1 \approx 0.5$$

物理问题

磁序消失后，基态如何组织？

自旋液体，还是自旋配对形成的有序态？

计算难点

能量差小，需同时比较能量与关联。



ED 规模有限，常规 QMC 有符号问题。

这个模型同时检验波函数的表达能力、计算精度与可达到的系统规模。

Benchmark calculations on J1-J2 model

Spin $\frac{1}{2}$ $J_1 - J_2$ square Heisenberg model :


$$H = J_1 \sum_{\langle ij \rangle} S_i \cdot S_j + J_2 \sum_{\langle\langle ij \rangle\rangle} S_i \cdot S_j$$



PEPS++：能量精度的检验

4×6 格点, $J_2/J_1 = 0.5$, 开放边界, 与 ED 精确结果比较。

PEPS++ = PEPS + 蒙特卡洛采样 + 梯度优化



相同键维数 $D = 10$



采样与梯度优化后的
相对能量误差

$$\approx 3 \times 10^{-5}$$

较简单更新缩小约 42 倍

Liu 等, PRB 95, 195154 (2017)

张量网络的表示形式确定后, 优化方法仍会显著影响结果的精度。




20Pflops

Implemented on Sunway-Taihu Light
(10 million cores)

It is possible to calculate J1-J2 model on 24×24 lattice with $D=16$.

PEPS++：磁序的有限尺寸分析

从不同大小的晶格出发，判断无限大系统中是否仍有 Néel 磁序。



怎样读图

纵轴：Néel 磁序强度

$W = L - 4$ ：中心区域边长

$1/W \rightarrow 0$ ：外推到无限大系统

$L = 8-16, D = 8$

该工作 (2018) 的结果

$J_2/J_1 \approx 0.42$ 附近，
Néel 磁序的外推值趋于零。


Liu 等, PRB 98, 241109(R) (2018), 图 2

确认自旋液体还需检查其他有序方式，不能只看 Néel 磁序是否消失。

PEPS++：自旋液体的数值证据


$J_2/J_1 = 0.5、0.55$ ：检查配对有序与关联函数（2018 年工作）。

配对有序的尺寸外推



外推到无限大系统，配对有序接近零。

配对关联随距离衰减




有限距离内，关联与幂律衰减相容。

综合这些证据，论文支持无隙自旋液体解释，仍未排除极弱的配对有序。

J_1 - J_2 模型的基本相图

$$H = J_1 \sum_{\langle i,j \rangle} \mathbf{S}_i \cdot \mathbf{S}_j + J_2 \sum_{\langle\langle i,j \rangle\rangle} \mathbf{S}_i \cdot \mathbf{S}_j$$

J_1 : 最近邻耦合 J_2 : 次近邻耦合





示意图不标定相边界；下方展示中间区域的候选态。

量子自旋与图像识别的网络对比

两类任务都用网络表达概率，但概率所描述的对象不同。

量子自旋



输出：概率

$$p_{\theta}(s)$$

这个磁构型出现的概率

由振幅模平方归一化得到

图像识别



图片 x



$$p_{\varphi}(y | x)$$

示例概率

猫：95%

狗：4%


其他：1%

给定这张图片，
属于各类别的概率

同样是“输入 → 网络 → 概率”，概率的含义由任务决定。

第二部分小结：量子态的表示与优化

波函数由网络表示，物理能量决定参数如何优化。



固定 D 时, 参数量随 N 多项式增长; 一般 PEPS 的精确收缩仍有困难。

下一部分：神经网络能否成为另一种多体波函数表示？

机器学习与量子多体问题


第三部分

神经网络量子态

用神经网络表示与求解量子多体问题

何力新


中国科学技术大学



自旋模型与神经网络的物理联系

二值变量与成对耦合，可以同时描述经典自旋和二值神经元。

经典 Ising 自旋




$$s_i = \pm 1$$

$$E(s) = - \sum_{i < j} J_{ij} s_i s_j$$

数学对应



二值神经元：Hopfield 网络



$$x_i = \pm 1$$

$$E(x) = - \sum_{i < j} w_{ij} x_i x_j$$


1982年

2024年诺贝尔物理学奖：Hopfield（联想记忆）与 Hinton（玻尔兹曼机）

物理模型的数学结构，也可以成为信息处理与学习的模型。

Hopfield 网络示意图

Recurrent associative memory model



1 binary neurons

神经元为二值状态: $s_i \in \{+1, -1\}$

2 recurrent network

全连接的递归网络 (recurrent):
每个神经元都与其他所有神经元相互连接。

3 symmetric weights

连接权重对称: $w_{ij} = w_{ji}$ 。

4 no self-connections

没有自连接: $w_{ii} = 0$ 。

5 memory attractor

网络通过迭代更新会收敛到稳定状态 (记忆吸引子)。

能量函数 (Lyapunov 函数)

$$E = -\frac{1}{2} \sum_{i \neq j} w_{ij} s_i s_j$$


在异步更新下, 网络的能量单调不增,
最终收敛到局部最小值 (吸引子)。

神经元更新规则 (异步更新)

$$s_i \leftarrow \text{sign} \left(\sum_{j \neq i} w_{ij} s_j \right)$$

$$\text{sign}(x) = \begin{cases} +1, & x \geq 0 \\ -1, & x < 0 \end{cases}$$


能量景观示意图



核心思想: Hopfield 网络通过递归的相互作用, 使系统从任意初始状态收敛到一个存储的记忆模式 (吸引子)。

受限玻尔兹曼机 (RBM)

只保留层间连接，用隐藏变量描述可见变量之间的关联。



“受限”：同层节点之间没有连接

能量决定联合构型的概率

$$P(v, h) = \frac{1}{Z} \exp[-E(v, h)]$$

E 越低，联合构型的概率越大

Z 保证所有联合构型的概率之和为 1

$$p(v) = \sum_h P(v, h)$$


对所有隐藏构型求和，得到 $p(v)$

学习网络参数，就是调整不同可见构型出现的概率。

受限玻尔兹曼机 (RBM)

用能量描述构型概率，用隐藏单元表达变量关联

结构：两层随机变量



受限：层间相连，同层无连接

这里采用二值变量： $v_i, h_j \in \{-1, +1\}$

原理：从能量到概率

① 为联合构型定义能量

$$E(\mathbf{v}, \mathbf{h}) = -\sum_i a_i v_i - \sum_j b_j h_j - \sum_{ij} W_{ij} v_i h_j$$

② 能量越低，联合构型越可能出现

$$P(\mathbf{v}, \mathbf{h}) = \frac{e^{-E(\mathbf{v}, \mathbf{h})}}{Z} \quad Z: \text{归一化因子}$$

③ 对隐藏构型求和，得到可见构型的概率

$$p(\mathbf{v}) = \sum_{\mathbf{h}} P(\mathbf{v}, \mathbf{h})$$

同一可见构型，可以对应多种隐藏构型。


学习：调节 W 、 a 、 b ，让训练数据对应的构型具有更高概率。

量子态建模：借用隐藏变量求和的结构表示波函数 $\psi_{\theta}(s)$ ，再以能量期望为目标优化。

参考：G. Hinton, *A Practical Guide to Training Restricted Boltzmann Machines* (2010)

用 RBM 表示量子波函数


Carleo 与 Troyer, Science 355, 602–606 (2017)




$$\psi_\theta(s) = \sum_h \exp[a \cdot s + b \cdot h + s^T W h]$$

a 、 b : 偏置 W : 连接权重 参数 $\theta = \{a, b, W\}$ 可为复数

同一组网络参数，定义所有自旋构型的波函数振幅。



Restricted Boltzmann Machine (RBM)




G.S. feature map

Carleo and Troyer, Science **355**, 602–606 (2017)

Neural network for many-body problem

$$H = \sum_{i < j} J_{i,j} S_i \cdot S_j \quad \text{Heisenberg model}$$

$$\Psi_M(S; \mathcal{W}) = \sum_{\{h_i\}} e^{\sum_j a_j \sigma_j^z + \sum_i b_i h_i + \sum_{ij} W_{ij} h_i \sigma_j^z}$$



Can not treat frustrated systems !

波函数的符号结构与阻挫

两个自旋的例子：沿 z 方向测量，构型概率相同，量子态却不同。

相同符号的叠加

$$|\psi_+\rangle = (|\uparrow\downarrow\rangle + |\downarrow\uparrow\rangle) / \sqrt{2}$$

 
概率 $1/2$

 
概率 $1/2$

$$E_+ = +J/4$$

相反符号的叠加

$$|\psi_-\rangle = (|\uparrow\downarrow\rangle - |\downarrow\uparrow\rangle) / \sqrt{2}$$

 
概率 $1/2$

 
概率 $1/2$

$$E_- = -3J/4$$


同一个 Heisenberg 模型： $H = J S_1 \cdot S_2$, $J > 0$

阻挫模型的一项挑战：学习大量构型之间的复杂符号关系。

网络需要同时学好振幅的大小与相对符号（或相位）。

自旋构型也可以看作一幅图像

上下自旋对应两种像素值，二维晶格自然对应二维数组。



局部连接：提取邻近自旋的组合特征


参数共享：同一卷积核扫描不同位置

Liang 等, Phys. Rev. B 98, 104426 (2018) ; Mach. Learn.: Sci. Technol. 4, 015035 (2023)


把晶格的空间结构，直接用于神经网络的设计。

卷积神经网络表示量子多体波函数

输入一个自旋构型，输出它在多体波函数中的权重



一个卷积模块的内部



卷积提取关联, 最大池化引入非线性。

网络如何表示量子态

$$W_{\text{CNN}}(S) = \prod_i f_i(S)$$

$$|\Psi_{\text{CNN}}\rangle = \sum_S W_{\text{CNN}}(S) |S\rangle$$

权重可正可负

构型概率与 $|W_{\text{CNN}}(S)|^2$ 成正比

同一组网络参数, 为所有自旋构型给出权重。

结构依据: Liang, Dong & He, Phys. Rev. B 103, 035138 (2021), Fig. 1
早期结构: Phys. Rev. B 98, 104426 (2018)

以能量为目标的网络训练

Hamiltonian 给出评价标准，训练不需要已知的基态振幅标签。


目标：最小化能量

$$E(\theta) = \frac{\langle \psi(\theta) | H | \psi(\theta) \rangle}{\langle \psi(\theta) | \psi(\theta) \rangle}$$

H 已知, θ 可调

按当前波函数采样

$$p(s) \propto |\psi(s)|^2$$



估计能量与梯度


结合模型 H 与网络振幅

$$E(\theta), \nabla E(\theta)$$

判断参数的调整方向

采样分布随网络参数一起变化

更新网络参数




权重与偏置 θ

训练样本来自当前波函数，优化目标来自物理模型。

SR: 考虑量子态变化的优化

相同大小的参数改动，可以让量子态发生不同程度的变化。



SR 结合能量梯度与量子态的变化，调整更新方向和步幅。


Stochastic Reconfiguration (随机重构)

SR 与自然梯度的思想相通：用量子态的几何结构指导优化。

我们的工作：CNN 求解 J_1 - J_2 模型

Liang 等, Mach. Learn.: Sci. Technol. 4, 015035 (2023)

J_1 - J_2 模型 (周期边界)



局部耦合示意

— J_1 最近邻

--- J_2 对角耦合

$$J_1 = 1, J_2 = 0.5 \text{ (强阻挫)}$$

MCMC 采样 + SR 优化

用于自旋模型的 CNN1

6 个卷积模块



s



$$\psi_{\theta}(s)$$

每个模块：卷积、最大池化与转置卷积

106 529 个网络参数


结合符号预处理与晶格旋转对称性

一步 Lanczos 改进

通过 CNN 表示与变分优化，寻找强阻挫模型的低能态。

CNN 的能量结果

$J_1 = 1, J_2 = 0.5$, 周期边界, 每个自旋的能量 $E / (N J_1)$ 。



同一系统内

能量进一步降低

CNN + SR

优化网络参数

Lanczos 改进

扩展波函数的变化方向


神经网络得到变分波函数后, 仍可结合物理方法进一步改进。

图像分类与量子态表示

输入都可以按图像组织，网络输出的含义由任务决定。

图像分类

示例概率




输出的含义

$$p_{\varphi}(y | x)$$

猫 95% 狗 4% 其他 1%

各类别概率之和为 1

量子态表示


$$\psi_{\theta}(s)$$

构型的系数，包含符号或相位

$$p_{\theta}(s) \propto |\psi_{\theta}(s)|^2$$

对所有构型的概率归一化

学习的对象可以是分类规则，也可以是整个量子态。

训练目标、样本与评价

物理规律提供自监督信号，无需预先给出基态振幅标签。

比较内容	图像分类（监督学习）	量子基态（自监督学习）
已知信息	图像 x 与类别标签 y 标签提供正确答案	哈密顿量 H 物理规律提供学习信号
训练样本	从给定训练集抽取批次 可结合图像增强	按当前波函数抽样 分布随参数更新而变化
优化目标	最小化交叉熵 让类别预测符合标签	最小化变分能量 $E(\theta)$ 在变分空间中逼近基态
结果评价	独立测试集上的准确率 检查对新图像的泛化	能量与物理关联函数 检查统计误差与收敛

这里的自监督信号来自哈密顿量与变分原理。

网络表示与学习任务

网络提供函数表示，数据或物理规律提供学习信号。




任务示例	希望表示的函数	优化目标
图像分类	类别概率 $p(y x)$	交叉熵
概率建模	数据分布 $p(x)$	负对数似然
量子基态 (自监督)	波函数 $\psi(s)$	变分能量

表示方式与学习目标，需要围绕具体任务共同设计。

全课回顾与讨论


共同主线：用可训练的函数表示，探索复杂的高维问题。

量子多体问题




指数增长的构型空间
叠加、纠缠与阻挫

张量网络



结构化的波函数表示
SVD、MPS、PEPS

神经网络



可训练的波函数表示
RBM、CNN、SR 优化

物理规律提供自监督信号，变分优化寻找低能态。

讨论：在你的研究中，没有标签时可以怎样定义学习目标？