

课程论文导读

本次课程围绕医学图像分析的六个核心方向展开论文研讨，选取从经典方法到前沿研究的代表性工作，重点关注不同技术范式的演进过程。六个专题分别为：[医学图像分割](#)、[医学图像翻译](#)、[医学图像分类](#)、[医学图像检测](#)、[医学图像三维重建](#)、[医学图像智能体](#)。

医学图像分割

专题概览：医学图像分割的发展经历了从任务特定的深度网络设计，到数据驱动的自动配置，再到跨任务、跨模态的通用分割模型，近年来进一步进入医学视觉基础模型阶段。本专题选取的四篇论文分别代表了 [U-Net 基础架构](#)、[自动化分割范式](#)、[Universal Segmentation](#) 和 [Open-world Foundation Model](#) 四个阶段，体现了医学图像分割从“针对单一任务设计模型”向“一个模型适应多种任务和开放世界场景”的发展趋势。

1. **Ronneberger O, Fischer P, Brox T.** U-net: Convolutional networks for biomedical image segmentation[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Cham: Springer International Publishing, 2015: 234-241.

论文导读：U-Net 是医学图像分割领域最具代表性的经典工作之一，采用对称的 Encoder-Decoder 结构以及跨层 Skip Connection，将高层语义信息与低层空间细节进行融合。其核心思想简单而有效，在医学图像数据量有限、目标边界复杂的场景下表现出很强的适应性，并成为此后大量医学图像分割方法的基础架构。

核心启示：医学图像分割的关键不仅是理解“是什么”，还需要精确回答“在哪里”，U-Net 创新性地通过多尺度特征融合解决了语义理解和空间定位之间的矛盾。

2. **Isensee F, Jaeger P F, Kohl S A A, et al.** nnU-Net: A self-configuring method for deep learning-based biomedical image segmentation[J]. Nature Methods, 2021, 18(2): 203-211.

论文导读: nnU-Net 并没有提出一个更加复杂的分割网络，而是系统研究医学图像分割中 preprocessing、网络配置、训练策略和后处理等因素的影响，并根据具体数据集自动配置完整训练流程。研究表明，一个经过系统配置的标准化 pipeline 就能够在大量医学分割任务上达到非常强的性能。

核心启示: 医学 AI 的性能并不只取决于网络结构，数据处理、训练策略和实验配置同样重要；研究范式开始从“设计更复杂的模型”转向“构建更加可靠的自动化方法”。

3. **Butoi V I, Ortiz J J G, Ma T, et al.** UniverSeg: Universal medical image segmentation[C]//2023 IEEE/CVF International Conference on Computer Vision (ICCV). IEEE, 2023: 21381-21394.

论文导读: UniverSeg 进一步突破“一个数据集训练一个模型”的范式，通过支持集（support set）向模型提供少量示例，使模型可以在未见过的医学分割任务上直接完成预测，而无需重新训练。该工作展示了医学图像分割从数据集级泛化向任务级泛化的转变。

核心启示: 真正的通用模型不应只是在多个数据集上取得高性能，而应该能够面对新的任务时，通过少量示例快速适应。

4. **Zhang S, Zhang Q, Zhang S, et al.** A generalist foundation model and database for open-world medical image segmentation[J]. Nature Biomedical Engineering, 2025: 1-16.

论文导读: 该工作进一步面向开放世界医学图像分割，构建大规模医学分割数据库和通用基础模型，使模型能够处理更加多样的医学任务，并关注域外数据和真实临床场景中的泛化能力。研究将医学图像分割从“多任务泛化”进一步推进到“开放世界医学视觉基础模型”。

核心启示: Foundation Model 的关键价值不只是覆盖更多数据和任务，更重要的是面对未知分布和开放场景时仍具有可靠的泛化能力。

专题总结: U-Net → nnU-Net → UniverSeg → Open-world Foundation Model, 这一专题反映了医学分割研究从“如何设计更好的网络”逐渐转向“如何构建能够泛化到新任务和新场景的通用模型”。

医学图像翻译

专题概览：医学图像翻译关注从一种医学图像或染色形式生成另一种形式，其研究范式逐渐从传统的视觉域转换发展到具有明确生物学意义的生成任务。本专题以病理虚拟染色为主要脉络，展示了从 **Virtual Staining** → **Special Stain** → **Virtual Multiplexing** → **Virtual Population** 的演进过程。

1. **Rivenson Y, Wang H, Wei Z, et al.** Virtual histological staining of unlabelled tissue-autofluorescence images via deep learning[J]. Nature Biomedical Engineering, 2019, 3(6): 466-477.

论文导读：该工作利用未染色组织的自发荧光图像，通过深度学习生成虚拟组织染色结果，从而以计算方式替代传统物理染色过程。其核心意义在于证明深度学习可以将未染色组织转换为具有组织学意义的虚拟染色图像，为虚拟病理染色奠定了重要基础。

核心启示：图像翻译不仅可以追求视觉上的相似性，还可以用于模拟实验过程和获取新的医学信息。

2. **De Haan K, Zhang Y, Zuckerman J E, et al.** Deep learning-based transformation of H&E stained tissues into special stains[J]. Nature Communications, 2021, 12(1): 4884.

论文导读：该工作进一步将虚拟染色从“无染色组织→H&E”推进到“H&E→特殊染色”，能够生成 PAS、Masson's Trichrome、Jones 等特殊染色结果。相比单纯进行图像风格转换，这一研究进一步展示了虚拟染色在病理诊断中的潜在价值。

核心启示：虚拟病理染色开始从“替代物理染色”走向“拓展诊断信息”。

3. **Pati P, Karkampouna S, Bonollo F, et al.** Accelerating histopathology workflows with generative AI-based virtually multiplexed tumour profiling[J]. Nature Machine Intelligence, 2024, 6(9): 1077-1093.

论文导读：Virtual Multiplexer 从单张 H&E 图像生成多个虚拟 IHC 标记，从而模拟多重分子检测过程，并进一步利用这些虚拟标记开展肿瘤表型分析。该工作将图像生成与肿瘤生物学分析连接起来，使虚拟染色从单个染色结果生成扩展到多标记联合分析。

核心启示：生成模型不仅是在“生成图像”，更是在尝试从形态学信息推断潜在的分子和生物学状态。

4. **Valanarasu J M J, Xu H, Usuyama N, et al.** Multimodal AI generates virtual population for tumor microenvironment modeling[J]. Cell, 2026, 189(2): 386-400.e19.

论文导读：该工作进一步将生成式医学图像分析扩展到群体和微环境建模，通过多模态 AI 生成具有生物学意义的虚拟肿瘤微环境及虚拟患者群体。其研究目标已经超越单张图像的转换，而是利用生成模型构建新的生物医学数据空间，用于肿瘤微环境研究。

核心启示：医学图像翻译的最终价值可能并非生成一张“逼真的图像”，而是生成可用于科学研究的新型生物医学数据。

专题总结： Virtual Staining → Special Stain Translation → Virtual Multiplexing → Virtual Population，该专题体现了生成式 AI 在医学领域中的一个重要变化：从“生成视觉上真实的图像”逐渐走向“生成具有生物学和临床意义的信息”。

医学图像分类

专题概览：医学图像分类是医学 AI 最早取得显著突破的任务之一，其研究逐渐经历了从单一疾病的监督学习，到大规模弱监督学习，再到基础模型和可信医学 AI 的演变。本专题重点展示 **Task-specific Classification → Weakly-supervised Clinical AI → Foundation Model → Auditable Foundation Model** 的发展路线。

1. **Esteva A, Kuprel B, Novoa R A, et al.** Dermatologist-level classification of skin cancer with deep neural networks[J]. Nature, 2017, 542(7639): 115-118.

论文导读：该工作使用大规模皮肤病图像训练深度神经网络，并将模型结果与皮肤科医生进行比较，展示深度学习在皮肤癌分类中的临床潜力。论文是医学图像深度学习领域的经典代表之一，标志着医学图像分类开始从实验室任务走向临床级诊断问题。

核心启示：深度学习不仅能够在医学图像分类 benchmark 上取得较高准确率，而且有潜力达到专业医生水平。

2. **Campanella G, Hanna M G, Geneslaw L, et al.** Clinical-grade computational pathology using weakly supervised deep learning on whole slide images[J]. Nature Medicine, 2019, 25(8): 1301-1309.

论文导读：针对 whole-slide image 标注成本极高的问题，该工作利用 slide-level diagnosis 进行弱监督学习，通过 Multiple Instance Learning 直接从整张病理切片学习癌症相关表征。研究证明，大规模弱标注数据也能够训练具有临床级性能的病理 AI。

核心启示：医学 AI 的核心瓶颈不仅是模型，也包括数据标注；弱监督学习为利用真实世界海量临床数据提供了重要路径。

3. **Zhou Y, Chia M A, Wagner S K, et al.** A foundation model for generalizable disease detection from retinal images[J]. Nature, 2023, 622(7981): 156-163.

论文导读：RETFound 利用大规模无标注 retinal images 进行自监督预训练，学习通用 retinal representation，再迁移到多种疾病检测任务。相比为每种疾病单独训练分类器，该工作开始构建一个能够服务多个任务的医学视觉基础模型。

核心启示：医学 AI 的研究重点开始从“训练一个任务模型”转向“学习通用医学视觉表征”。

4. **Han T, Wu R, Tian Y, et al.** CLEAR: An auditable foundation model for radiology grounded in clinical concepts[J]. Nature Biomedical Engineering, 2026: 1-16.

论文导读：CLEAR 在医学视觉基础模型的基础上进一步引入临床概念和可审计机制，使模型不仅能够进行疾病预测，还能够从临床概念层面对预测依据进行解释和审查。该工作体现了医学基础模型从“更强泛化能力”走向“更加可信和可审计”的发展趋势。

核心启示：医疗领域不仅需要高性能模型，还需要知道模型“为什么这么判断”以及“是否依据了合理的医学证据”。

专题总结：Task-specific Classification → Weakly-supervised Clinical AI → Foundation Model → Auditable Foundation Model 这一专题体现了医学图像分类研究从“AI 能不能诊断？”→“如何低成本利用临床数据？”→“如何让一个模型服务多个任务？”→“如何让基础模型可信？”的演进过程。

医学图像检测

专题概览：这里的“检测”特指对医学图像中的病灶、结节、肿瘤等目标进行**定位和检测**，而非单纯判断图像中是否存在疾病。本专题体现了从针对特定病灶设计**专用检测器**，到**通用医学目标检测框架**，再到语言视觉模型和**医学视觉基础模型**的发展过程。

1. **Tang H, Zhang C, Xie X.** NoduleNet: Decoupled false positive reduction for pulmonary nodule detection and segmentation[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Cham: Springer International Publishing, 2019: 266-274.

论文导读：NoduleNet 针对肺结节检测中的高假阳性问题，将目标检测与分割结合，通过进一步利用结节的形态和边界信息降低误检。该工作代表了早期医学病灶检测中典型的任务特定模型设计思路。

核心启示：医学目标检测与自然图像检测存在明显差异，病灶通常尺度小、边界模糊且存在大量相似组织，因此需要引入更加丰富的医学结构信息。

2. **Baumgartner M, Jäger P F, Isensee F, et al.** nnDetection: A self-configuring method for medical object detection[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Cham: Springer International Publishing, 2021: 530-539.

论文导读：nnDetection 延续 nnU-Net 的思想，不再针对某一种病灶手工设计检测网络，而是根据不同医学数据的特点自动配置 preprocessing、网络结构和训练策略。它代表医学目标检测从“专用模型”向“通用检测框架”的转变。

核心启示：医学目标检测的研究重点逐渐从设计复杂的 detector 转向建立能够适应不同数据和任务的通用方法论。

3. **Liu J, Zhang Y, Wang K, et al.** Universal and extensible language-vision models for organ segmentation and tumor detection from abdominal computed tomography[J]. Medical Image Analysis, 2024, 97: 103226.

论文导读：该工作引入语言视觉表示，通过语言 embedding 描述不同器官和肿瘤类别，使模型能够扩展到新类别，并统一处理器官分割与肿瘤检测。

它体现了医学视觉任务从固定类别向语言驱动、可扩展模型的发展。

核心启示：当类别不再通过固定的 one-hot ID 表示，而是由语言进行描述时，医学检测模型开始具备更加灵活的任务接口。

4. **Zhao T, Gu Y, Yang J, et al.** A foundation model for joint segmentation, detection and recognition of biomedical objects across nine modalities[J]. Nature Methods, 2025, 22(1): 166-176.

论文导读：BiomedParse 将 segmentation、detection 和 recognition 统一到同一个医学视觉基础模型中，并覆盖多种医学图像模态，使检测成为通用医学视觉模型的一种基本能力。该工作标志着医学目标检测进一步融入 Foundation Model 范式。

核心启示：当一个基础模型能够统一完成多个视觉任务时，传统任务边界逐渐被打破，医学 AI 从“任务模型”向“通用能力模型”转变。

专题总结：Task-specific Lesion Detection → Self-configuring Detection → Language-driven Universal Detection → Biomedical Foundation Model, 类似地，其发展重点从“如何检测一个病灶”逐渐转向“如何构建能够检测未知医学目标的通用模型”。

医学图像重建

专题概览：本专题中的“重建”特指从医学图像构建三维人体目标，如器官、血管和心脏等，而不是传统意义上的 MRI/CT 图像重建。相关研究逐渐从基于二维投影的三维器官重建，发展到隐式三维形状建模，再到个体化动态 4D 结构生成和稀疏条件下的动态三维重建。

1. **Wang Y, Zhong Z, Hua J.** DeepOrganNet: On-the-fly reconstruction and visualization of 3D/4D lung models from single-view projections by deep deformation network[J]. IEEE Transactions on Visualization and Computer Graphics, 2019, 26(1): 960-970.

论文导读：DeepOrganNet 从单视角投影图像中快速恢复个体化的 3D/4D 肺部模型，其核心思想是学习从标准解剖模板到患者个体结构之间的 deformation。该工作说明二维医学观测结合解剖先验后，可以用于恢复不

可直接观测的三维人体结构。

核心启示：3D 医学结构重建本质上是一个强先验的逆问题，模型需要同时利用图像证据和人体解剖结构规律。

2. **Yang J, Wickramasinghe U, Ni B, et al.** ImplicitAtlas: Learning deformable shape templates in medical imaging[C]//2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2022: 15840-15850.

论文导读：ImplicitAtlas 将可变形解剖模板与神经隐式表示结合，通过连续的隐式函数描述三维器官和病灶形状，并学习患者之间的形态变化。相比传统显式 mesh 或 voxel 表示，该方法能够更加灵活地表达复杂的三维解剖结构。

核心启示：随着三维生成技术的发展，医学结构不再一定需要由显式体素或网格表示，implicit representation 为医学 3D shape modeling 提供了新的表达方式。

3. **Qiao M, McGurk K A, Wang S, et al.** A personalized time-resolved 3D mesh generative model for unveiling normal heart dynamics[J]. Nature Machine Intelligence, 2025, 7(5): 800-811.

论文导读：MeshHeart 利用大规模心脏 MRI 数据学习个体化的 3D cardiac mesh，并进一步建模一个完整心动周期中的动态变化，从而生成个体化、时间分辨的 3D 心脏结构。研究将医学三维重建从静态结构进一步扩展到动态人体建模。

核心启示：医学三维结构不仅具有空间维度，也具有时间维度；未来的解剖建模需要同时描述形态和运动。

4. **Zhu Y, Wang Y, Di C, et al.** Sparse and transferable three-dimensional dynamic vascular reconstruction for instantaneous diagnosis[J]. Nature Machine Intelligence, 2025, 7(5): 730-742.

论文导读：该工作研究在稀疏医学观测条件下构建动态三维血管结构，并强调不同场景之间的迁移能力。其研究目标从“重建一个静态三维目标”进一步扩展到“在信息不完整时恢复动态、可迁移的三维人体结构”。

核心启示：未来三维重建的核心难点不仅是结构表达，还包括有限观测、动态变化以及跨患者和跨场景泛化。

专题总结：Single-view 3D Reconstruction → Implicit Shape Modeling → Personalized 4D Generation → Dynamic and Transferable Reconstruction，该专题的核心问题不是“识别是什么”，而是如何从有限二维观测推断不可直接观测的三维人体世界。因此它天然连接了逆问题、几何深度学习、隐式神经表示和生成模型。

医学图像智能体

专题概览：医学图像智能体代表医学 AI 从“模型”向“系统”的进一步演进。其核心不再是单一模型完成一个固定任务，而是让 AI 能够理解问题、调用医学工具、组织多个模型、执行多步骤任务并最终形成综合决策。本专题体现了 **LLM + CAD → Tool-use Agent → Multi-Agent → Autonomous Scientific Agent** 的发展路径。

1. **Zhao Z, Wang S, Gu J, et al.** ChatCAD+: Toward a universal and reliable interactive CAD using LLMs[J]. IEEE Transactions on Medical Imaging, 2024, 43(11): 3755-3766.

论文导读：ChatCAD+将大型语言模型作为医学影像 CAD 系统的统一交互和推理中枢，通过连接已有的医学影像分析模型来完成诊断、报告生成和交互式问答。它代表了早期 LLM 与专业医学视觉模型结合的探索。

核心启示：医学领域已经积累了大量专业的分类、检测和分割模型，LLM 的一个重要价值是将这些分散的能力组织起来。

2. **Li B, Yan T, Pan Y, et al.** MMedAgent: Learning to use medical tools with multi-modal agent[C]//Findings of the Association for Computational Linguistics: EMNLP 2024. 2024: 8745-8760.

论文导读：MMedAgent 将不同医学视觉模型视为可调用的 tools，使 Agent 根据用户需求自主选择合适的工具完成多模态医学任务，包括分类、分割、定位、问答和报告生成等。相比 ChatCAD+，该工作进一步强调 Agent 的自主工具使用能力。

核心启示：Tool Use 是从“医学助手”走向“医学智能体”的重要分界点，Agent 不再只是整合结果，而是开始自主决定“下一步应该做什么”。

3. **Ghezloo F, Seyfioglu M S, Soraki R, et al.** PathFinder: A multi-modal multi-agent system for medical diagnostic decision-making applied to histopathology[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2025: 23431-23441.

论文导读: PathFinder将病理诊断过程拆解为多个相互协作的专业 Agent, 包括病例筛选、区域导航、图像描述和诊断等, 使 AI 能够模拟病理医生逐步浏览和分析 whole-slide image 的工作流程。

核心启示: Multi-Agent 的价值不仅在于“多个模型一起工作”, 更在于将复杂医学任务拆解成多个具有不同职责的子任务。

4. **Trost F, Zhang B, Aring I, et al.** An agentic framework for autonomous scientific discovery in cancer pathology[J]. Nature Medicine, 2026: 1-13.

论文导读: 该工作进一步将 Agent 的能力从临床诊断扩展到癌症病理科学研究, 使 Agent 能够参与数据分析、模式发现、假设构建和科学验证等过程。AI 的角色由“帮助医生完成任务”转变为“帮助科学家开展研究”。

核心启示: Agent 的最终价值可能并不是替代某一个医学模型, 而是将感知、推理、工具使用和科学分析组织成一个能够自主执行复杂任务的系统。

专题总结: LLM + CAD → Tool-use Agent → Multi-Agent Workflow → Autonomous Scientific Agent, 体现了一个非常明显的变化: AI 从“模型”变成“能够使用模型的系统”。前五个专题关注的是分类、检测、分割、生成和三维重建等具体能力, 而智能体进一步将这些能力组织起来, 使 AI 能够: 感知→推理→规划→工具调用→执行→验证→决策。最终进一步走向自主医学科学发现。