

生物专题课程论文导读

导读说明

本次课程围绕 AI4Bio 领域的六个核心方向展开论文研讨。六个专题分别为：蛋白质结构预测、复合物与结构基础模型；生成式蛋白质设计与蛋白药物；基因组与分子序列基础模型；单细胞与空间组学基础模型；AI 药物发现、分子建模与生物逆合成；生物领域智能体与自主科研。

蛋白质结构预测、复合物与结构基础模型

专题概览

蛋白质是由氨基酸组成的长链，折叠后的三维形状决定其与其他分子相互作用的方式。传统结构测定需要较长时间和大量实验，本专题介绍人工智能如何从序列推断蛋白质结构，并进一步描述蛋白质与核酸、小分子等形成的复合物。四篇论文体现了从单个蛋白结构预测、蛋白组资源建设，到多种生物分子统一建模的发展过程。

01. Highly accurate protein structure prediction with AlphaFold

标准书目：Jumper John、Evans Richard、Pritzel Alexander 等. Highly accurate protein structure prediction with AlphaFold. Nature 596:583-589 (2021). DOI: 10.1038/s41586-021-03819-2。

论文导读：蛋白质在细胞中承担催化、运输和信号传递等工作，而它们的形状通常决定了这些功能。AlphaFold2 研究如何根据氨基酸序列和同源序列信息，直接推断蛋白质可能采用的三维结构，并在国际盲测中显示出接近实验结构的能力。这一工作让“先得到结构线索、再提出生物学问题”成为大规模研究流程。

核心启示：结构预测提供的是带有置信度的科学线索；低置信度区域、柔性区域和蛋白质功能仍需要实验研究。

02. Highly accurate protein structure prediction for the human proteome

标准书目：Tunyasuvunakool Kathryn、Adler Jonas、Wu Zachary 等. Highly accurate protein structure prediction for the human proteome. Nature 596:590-596 (2021). DOI: 10.1038/s41586-021-03828-1。

论文导读：单个蛋白的结构预测还可以进一步服务于整个物种的研究。该论文把 AlphaFold2 应用于几乎完整的人类蛋白组，整理出可检索的结构资源，并用若干蛋白说明这些预测怎样帮助研究者提出功能假说。它代表人工智能从一个算法转变为生物学基础设施的过程。

核心启示：使用结构数据库时要同时查看覆盖范围和置信度，不能把“有预测结构”理解为“每个位置都被实验确认”。

03. Accurate prediction of protein structures and interactions using a three-track neural network

标准书目：Baek Minkyung、DiMaio Frank、Anishchenko Ivan 等. Accurate prediction of protein structures and interactions using a three-track neural network. Science 373:871-876 (2021). DOI: 10.1126/science.abj8754。

论文导读：蛋白质结构同时受到序列、残基之间的几何关系和整体三维形状影响。RoseTTAFold 将这三类信息放在相互交流的三个通道中，既预测单个蛋白，也尝试处理蛋白相互作用，并把结果用于困难结构的实验解析。它说明不同层次的生物表示可以互相补充。

核心启示：计算结构的价值在于帮助实验设计和解释结果；结构预测本身不是疾病机制或相互作用的最终证明。

04. Accurate structure prediction of biomolecular interactions with AlphaFold 3

标准书目：Abramson Josh、Adler Jonas、Dunger Jack 等. Accurate structure prediction of biomolecular interactions with AlphaFold 3. Nature 630:493-500 (2024). DOI: 10.1038/s41586-024-07487-w。

论文导读：细胞中的重要对象往往是复合物，而不是孤立的蛋白质。AlphaFold3 把蛋白质、DNA、RNA、小分子、离子和修饰残基放进同一建模框架，展示了结构人工智能从蛋白质折叠走向分子相互作用的趋势。论文也提醒我们，复合物构象和化学合理性比单体结构更难判断。

核心启示：模型覆盖对象变多并不等于每种相互作用都可靠；候选结构仍要经过化学检查和实验验证。

专题总结

结构预测的里程碑 → 从模型到人类蛋白组资源 → 三轨表示与复合物建模 → 从蛋白扩展到生物分子复合物。这条线索用于课堂讨论，不能替代各论文的任务定义、数据拆分和实验细节。

生成式蛋白质设计与蛋白药物

专题概览

蛋白质设计的目标是根据需要创造自然界中没有的蛋白质，例如稳定的支架、结合靶标的蛋白或具有特定功能的酶。生成式人工智能可以在巨大的序列和结构空间中提出候选方案，但候选必须经过结构分析、结合实验和功能实验。本专题从骨架生成、序列设计、蛋白语言模型和肽结合物四个角度介绍这一过程。

05. De novo design of protein structure and function with RFdiffusion

标准书目：Watson Joseph L.、Juergens David、Bennett Nathaniel R. 等. De novo design of protein structure and function with RFdiffusion. Nature 620:1089-1100 (2023). DOI: 10.1038/s41586-023-06415-8。

论文导读：如果结构预测回答“自然蛋白可能长什么样”，蛋白质设计则进一步询问“我们能否按目标创造一个新蛋白”。RFdiffusion 根据给定的形状、功能位点、对称性或靶标提出蛋白骨架，再配合序列设计和结构筛选完成设计流程。结合物的结构实验说明这种方法可以产生真正可制备的候选。

核心启示：评价生成蛋白不能只看计算图像是否漂亮，还要依次检验表达、稳定性、结合和功能。

06. Robust deep learning-based protein sequence design using ProteinMPNN

标准书目：Dauparas J.、Anishchenko I.、Bennett N. 等. Robust deep learning-based protein sequence design using ProteinMPNN. Science 378:49-56 (2022). DOI: 10.1126/science.add2187。

论文导读：确定蛋白骨架后，还需要找到一条能够折叠成该形状的氨基酸序列。ProteinMPNN 把骨架看成由原子和空间邻接关系组成的图，快速给出多条可能序列，并通过表达、结构和功能实验展示它们的用途。它是蛋白设计 workflow 中连接“形状”和“序列”的关键环节。

核心启示：序列恢复率只能说明序列像不像已知骨架，不能单独保证蛋白可溶、稳定或有功能。

07. Large language models generate functional protein sequences across diverse families

标准书目：Madani Ali、Krause Ben、Greene Eric R. 等. Large language models generate functional protein sequences across diverse families. Nature Biotechnology 41:1099-1106 (2023). DOI: 10.1038/s41587-022-01618-2。

论文导读：天然蛋白序列像是漫长进化留下的“语言”。ProGen 用大量蛋白序列训练语言模型，并用家族和功能标签控制生成，研究者随后合成和测试模型提出的序列。部分序列与天然蛋白差异很大却仍有活性，说明模型可以探索自然进化没有充分覆盖的区域。

核心启示：语言模型能提出有希望的序列，但是否真正工作只能由独立的生化和结构实验回答。

08. De novo design of high-affinity binders of bioactive helical peptides

标准书目：Vázquez Torres Susana、Leung Philip J. Y.、Venkatesh Preetham 等. De novo design of high-affinity binders of bioactive helical peptides. Nature 626:435-442 (2024). DOI: 10.1038/s41586-023-06953-1。

论文导读：许多激素和信号肽在游离状态下很柔软，只有与受体结合时才形成稳定螺旋，因此为它们设计结合蛋白很困难。该研究结合结构生成、序列设计和实验筛选，得到多种高亲和力肽结合物，并进一步演示其在检测中的用途。它把生成设计与一个具体的生物医学问题连接起来。

核心启示：高亲和力是重要起点，真实样本中的特异性、稳定性和可重复使用性同样决定应用价值。

专题总结

按功能约束生成蛋白骨架 → 固定骨架的逆折叠序列设计 → 蛋白语言模型生成远离天然序列的功能 → 为柔性生物活性肽设计结合物。这条线索用于课堂讨论，不能替代各论文的任务定义、数据拆分和实验细节。

基因组与分子序列基础模型

专题概览

DNA 和蛋白质序列都包含与生物功能有关的模式。基因组模型学习调控元件、剪接和跨物种序列特征，蛋白质语言模型则把大量序列知识用于结构预测。本专题关注生物序列如何被切分和表示、模型如何利用长距离信息，以及从序列预测功能时数据划分和生物学验证的重要性。

09. Nucleotide Transformer: building and evaluating robust foundation models for human genomics

标准书目：Dalla-Torre Hugo、Gonzalez Liam、Mendoza-Revilla Javier 等. Nucleotide Transformer: building and evaluating robust foundation models for human genomics. Nature Methods 22:287-297 (2025). DOI: 10.1038/s41592-024-02523-z。

论文导读：基因组中有大量尚未标注功能的 DNA 序列。Nucleotide Transformer 通过阅读人类、其他人类基因组和多种物种的 DNA，学习可迁移的序列表示，再用于调控、组蛋白和剪接等任务。论文展示了训练数据的多样性和模型大小如何影响跨任务表现。

核心启示：基因组模型的分值依赖任务和数据拆分；预测一个变异与真正判定临床致病之间仍有距离。

10. DNABERT-2: Efficient Foundation Model and Benchmark for Multi-Species Genomes

标准书目：Zhou Zhihan、Ji Yan、Li Weijian 等. DNABERT-2: Efficient Foundation Model and Benchmark for Multi-Species Genomes. ICLR 2024 (2024)。

论文导读：DNA 不像自然语言那样有固定单词，如何切分序列会直接影响模型学习。DNABERT-2 用数据驱动的 BPE 词表代替固定长度的重叠 k-mer，并配合适合长序列的注意力方法，在多物种基准上评估迁移能力。它是理解“表示方式也是生物学模型假设”的清晰例子。

核心启示：更高效的分词可以节省计算，但必须通过跨物种、跨任务和严格拆分来检验是否真的学到生物规律。

11. Effective gene expression prediction from sequence by integrating long-range interactions

标准书目：Avsec Žiga、Agarwal Vikram、Visentin Daniel 等. Effective gene expression prediction from sequence by integrating long-range interactions. Nature Methods 18:1196-1203 (2021). DOI: 10.1038/s41592-021-01252-x。

论文导读：基因的表达常由距离很远的增强子调节，短窗口模型容易看不到这些联系。Enformer 使用很长的 DNA 序列和注意力机制，预测不同细胞和组织中的表达信号，并用扰动、群体遗传和报告实验数据进行检验。它把基因组模型从“读局部序列”推进到“理解长程调控”。

核心启示：相关性和统计因果线索有助于排序候选调控元件，但不能代替逐个位点的干预实验。

12. Evolutionary-scale prediction of atomic-level protein structure with a language model

标准书目：Lin Zeming、Akin Halil、Rao Roshan 等. Evolutionary-scale prediction of atomic-level protein structure with a language model. Science 379:1123-1130 (2023). DOI: 10.1126/science.ade2574。

论文导读：蛋白语言模型还可以把从序列中学到的进化规律用于结构预测。ESMFold 直接从单条序列快速生成结构，牺牲一部分精度换取很高的速度，因此适合扫描宏基因组中数量巨大的未知蛋白。大规模预测为发现新结构提供了入口，但不是实验结构数据库的替代品。

核心启示：使用快速预测时要理解速度、准确性和置信度之间的取舍，并注意模型训练数据带来的间接信息。

专题总结

跨物种DNA表示与迁移 → 让基因组分词更高效 → 把长程调控纳入表达预测 → 单序列快速折叠与宏基因组规模。这条线索用于课堂讨论，不能替代各论文的任务定义、数据拆分和实验细节。

单细胞与空间组学基础模型

专题概览

单细胞技术可以分别观察细胞的基因表达，帮助研究者认识组织中不同细胞的状态和相互作用。由于单细胞表达数据具有基因无顺序、零值多和批次差异等特点，不能简单照搬自然语言模型。本专题介绍生成式单细胞模型、大规模表达模型和网络生物学迁移学习，并指出当前选集主要聚焦单细胞转录组，空间组学仍有待补充。

13. scGPT: toward building a foundation model for single-cell multi-omics using generative AI

标准书目：Cui Haotian、Wang Chloe、Maan Hassaan 等. scGPT: toward building a foundation model for single-cell multi-omics using generative AI. Nature Methods 21:1470-1480 (2024). DOI: 10.1038/s41592-024-02201-0。

论文导读：单细胞表达数据记录的是“一个细胞里哪些基因被表达”，基因本身没有像句子那样的先后顺序。scGPT 重新设计了注意力和生成方式，让模型能够学习细胞表示，并用于细胞注释、批次整合、多组学整合和扰动预测。它代表把生成式语言模型思想改造成适合单细胞数据的尝试。

核心启示：模型输出可以帮助比较细胞状态，但不能把表达补全或注意力图直接当作真实调控和基因干预结果。

14. Large-scale foundation model on single-cell transcriptomics

标准书目：Hao Minsheng、Gong Jing、Zeng Xin 等. Large-scale foundation model on single-cell transcriptomics. Nature Methods 21:1481-1491 (2024). DOI: 10.1038/s41592-024-02305-7。

论文导读：单细胞数据通常非常稀疏，不同实验的测序深度也不同。scFoundation 通过连续表达值和大规模细胞语料学习通用表示，并把这些表示用于表达补全、药物敏感性和扰动预测等任务。论文让初学者看到，处理观测噪声和标签来源是单细胞基础模型的重要部分。

核心启示：补全出来的表达不是新增的实验读数，预测药物反应也需要独立的药效和因果验证。

15. Transfer learning enables predictions in network biology

标准书目：Theodoris Christina V.、Xiao Ling、Chopra Anant 等. Transfer learning enables predictions in network biology. Nature 618:616-624 (2023). DOI: 10.1038/s41586-023-06139-9。

论文导读：细胞状态之间的关系可以看成是一个复杂的生物网络。Geneformer 把每个细胞中相对重要的基因看成一段“细胞语言”，先在大规模细胞数据上学习，再迁移到疾病分类和候选基因筛选，并用心肌组织实验检验部分预测。它展示了从表示学习到可检验生物假说的完整例子。

核心启示：计算删除某个基因只是模拟实验的方式；只有在独立细胞或组织系统中验证后，候选才具有生物学说服力。

专题总结

面向非顺序单细胞数据的生成式模型 → 连续表达值与稀疏观测建模 → 从细胞排序表示到网络生物学。这条线索用于课堂讨论，不能替代各论文的任务定义、数据拆分和实验细节。

AI药物发现、分子建模与生物逆合成

专题概览

药物研发既要寻找能够结合靶标的分子，也要规划如何合成这些分子。生物催化逆合成利用酶促反应和已有实验先例倒推合成路线，分子对接则预测小分子在蛋白结合口袋中的姿态。本专题并列介绍这两类相邻任务，帮助初学者区分“规划反应路线”“预测结合姿态”和“生成新分子”。

16. RetroBioCat as a computer-aided synthesis planning tool for biocatalytic reactions and cascades

标准书目：Finnigan William、Hepworth Lorna J.、Flitsch Sabine L. 等. RetroBioCat as a computer-aided synthesis planning tool for biocatalytic reactions and cascades. *Nature Catalysis* 4:98-104 (2021). DOI: 10.1038/s41929-020-00556-z。

论文导读：逆合成是从目标分子倒推合成步骤。RetroBioCat 专门考虑酶促反应：它把已知酶反应规则、底物相似性和文献先例组织成可搜索的路线，帮助研究者寻找更温和或更具选择性的生物催化方案。论文的路线测试说明工具可以缩短规划过程，但不等于自动完成实验。

核心启示：可追溯的反应先例很有价值，真正可行的路线还要检查酶、辅因子、溶剂、温度和级联条件。

17. Biocatalysed synthesis planning using data-driven learning

标准书目：Probst Daniel、Manica Matteo、Nana Teukam Yves Gaetan 等. Biocatalysed synthesis planning using data-driven learning. *Nature Communications* 13:964 (2022). DOI: 10.1038/s41467-022-28536-w。

论文导读：ECREACT 把酶的功能类别作为反应预测的条件。模型既可以根据底物预测产物，也可以从目标产物倒推底物，并在化学反应数据和酶反应数据之间学习。它说明生物逆合成不能只看分子结构，还要把“什么酶能做这件事”纳入问题。

核心启示：酶类别标签比具体酶序列粗糙得多，模型预测的反应仍需选择真实酶并在实验条件下验证。

18. DiffDock: Diffusion Steps, Twists, and Turns for Molecular Docking

标准书目：Corso Gabriele、Stärk Hannes、Jing Bowen 等. DiffDock: Diffusion Steps, Twists, and Turns for Molecular Docking. *ICLR 2023* (2023).

论文导读：分子对接研究的是一个分子如何进入蛋白质的结合口袋，是药物发现中的重要步骤。

DiffDock 用扩散模型生成多种可能的结合姿态，再用置信度排序，速度和准确率较传统方法有所改

善。它与逆合成的目标不同：前者预测空间位置，后者规划化学反应。

核心启示：对接姿态是候选假说，不等于证明分子有效或亲和力高；新蛋白、柔性和物理合理性需要单独评估。

专题总结

把酶知识写进逆合成搜索 → 用酶类别条件化反应Transformer → 在几何流形上生成对接姿态。这条线索用于课堂讨论，不能替代各论文的任务定义、数据拆分和实验细节。

生物领域智能体与自主科研

专题概览

生物领域智能体是能够理解研究目标、调用数据库和分析软件、组织多个步骤并根据结果修正方案的人工智能系统。它与只回答问题的基础模型不同：智能体需要工具调用、任务规划、过程记录和结果核查，有些系统还把序列理解、多智能体协作与实验反馈连接起来。本专题四篇论文依次展示通用生物医学工具环境、DNA/RNA/蛋白序列对话、蛋白设计虚拟实验室，以及从文献到实验数据分析的科研闭环。

19. Biomni: A General-Purpose Biomedical AI Agent

标准书目：Tang Yuchen、Lian Liyuan、Chen Bo 等. Biomni: A General-Purpose Biomedical AI Agent. bioRxiv (2025). DOI: 10.1101/2025.05.30.656746。

论文导读：生物医学研究常常需要在数据库、统计程序和专业软件之间来回切换。Biomni 把这些资源整理成一个可调用的环境，让智能体把自然语言问题拆成数据检索、代码执行和结果解释等步骤，并记录每一步的操作。它帮助初学者理解“会调用工具”是生物智能体区别于普通聊天模型的基础。

核心启示：评价智能体要看工具是否选对、代码是否真正运行、分析过程能否复核，以及最后的生物学结论是否有独立证据支持。

20. A multimodal conversational agent for DNA, RNA and protein tasks

标准书目：de Almeida Bruno P. 等. A multimodal conversational agent for DNA, RNA and protein tasks. Nature Machine Intelligence 7:928-941 (2025). DOI: 10.1038/s42256-025-01047-1。

论文导读：DNA、RNA 和蛋白质序列分别记录遗传信息、调控信息和功能信息，但研究者通常需要不同的模型来处理它们。ChatNT 将序列编码器与语言解码器连接，把多种序列任务改写成可以用自然语言提问的形式。它代表智能体的一个重要入口：先让模型听懂生物序列，再让研究者以熟悉的对话方式使用模型。

核心启示：对话界面可以降低使用门槛，但不同任务仍需要分别评价，模型的置信度和可解释的序列 motif 不能替代实验测量。

21. The Virtual Lab of AI agents designs new SARS-CoV-2 nanobodies

标准书目：Swanson Kyle、Wu Wesley、Bulaong Nash L. 等. The Virtual Lab of AI agents designs new SARS-CoV-2 nanobodies. Nature 646:716-723 (2025). DOI: 10.1038/s41586-025-09442-9。

论文导读：蛋白设计往往需要免疫学、机器学习和结构生物学等不同知识。Virtual Lab 让承担不同角

色的智能体在研究会议中讨论目标、选择工具和编写流程，再由人类研究者安排实验验证。论文以新冠病毒纳米抗体为例，展示了多智能体协作怎样把序列模型、结构预测和能量评估连接成一条可执行的设计流程。

核心启示：多智能体分工和批评机制有助于提出更完整的方案，但计算候选必须经过表达、结合和功能实验，系统仍需要人类监督。

22. A multi-agent system for automating scientific discovery

标准书目：Ghareeb Ahmed 等. A multi-agent system for automating scientific discovery. Nature 655:497-505 (2026). DOI: 10.1038/s41586-026-10652-y。

论文导读：科研发现通常不是一次问答，而是提出假设、设计实验、分析数据，再据此提出下一轮问题。Robin 用不同智能体分别负责文献搜索、假设生成和实验数据分析，并在循环中整理证据。以年龄相关性黄斑变性研究为例，论文说明智能体如何帮助研究者从文献线索走向候选干预和转录组分析。

核心启示：生物科研智能体的价值体现在可追溯的假设迭代和实验闭环；人工执行实验、检查文献和判断结论仍是可靠研究不可缺少的环节。

专题总结

通用工具环境 → 序列对话接口 → 多智能体蛋白设计 → 文献与实验数据闭环。这条线索用于课堂讨论，不能替代各论文的任务定义、数据拆分和实验细节。

参考综述

- Notin et al., “Machine learning for functional protein design”, *Nature Biotechnology* 42, 216–228 (2024), DOI 10.1038/s41587-024-02127-0。以序列、结构、功能标签三种模态重新分类蛋白设计，并强调实验闭环和基准。
- Guo et al., “Diffusion models in bioinformatics and computational biology”, *Nature Reviews Bioengineering* 2, 136–154 (2024), DOI 10.1038/s44222-023-00114-9。覆盖蛋白、分子、对接和单细胞扩散模型。
- Ma et al., “Harnessing the deep learning power of foundation models in single-cell omics”, *Nature Reviews Molecular Cell Biology* 25, 593–594 (2024), DOI 10.1038/s41580-024-00756-6。讨论单细胞基础模型的进展、限制与最佳实践。
- van Breugel et al., “Synthetic data in biomedicine via generative artificial intelligence”, *Nature Reviews Bioengineering* 2, 991–1004 (2024), DOI 10.1038/s44222-024-00245-7。提醒隐私、偏差、分布移位和合成数据评估。
- “Embedding AI in biology”, *Nature Methods* 21, 1365–1366 (2024), DOI 10.1038/s41592-024-02391-7。编辑短文从成像、组学、蛋白结构等工作流概览AI嵌入生物学的方式。