

AI for Weather：从天气预报到地球系统预测

2026 年 9 月

目录

引言	2
一、论文清单	2
二、总体发展框架	4
三、专题一：全球天气预报	5
3.1 确定性预报器首先改变计算方式	5
3.2 基础模型扩展任务边界	6
3.3 概率集合扩展不确定性表达与高影响天气危险度预报	6
四、专题二：短临降水预报	6
4.1 从单一确定性预测到多种未来情景	7
4.2 物理引导与扩散模型分化为两条路线	7
五、专题三：次季节预报与气候模拟	8
5.1 情景代理：快速扩展可探索路径	8
5.2 次季节集合：寻找仍可预报的低频成分	8
5.3 高维全球大气场上的混合动力模型	8
5.4 物理场与气候模态的联合预测	9
六、专题四：海洋智能预报	9
6.1 区域海洋数字孪生	10
6.2 全球涡旋海洋预报	10
6.3 全球三维月尺度上层海洋预报／模拟	10
七、专题五：Benchmark 与可信评估	10
7.1 两条并行 Benchmark 分支	10
7.2 从平均技巧到极端事件压力测试	11
八、专题六：资料同化与分析—预报耦合	11
8.1 模型空间中的可微变分同化	12
8.2 面向真实卫星资料的直接融合	12
8.3 潜空间中的变分同化	12
九、建议阅读顺序	12
十、结语	12

引言

天气预报的基本任务，是根据当前大气和海洋状态推演未来。现代气象业务通常由观测系统、资料同化、数值模式和预报检验共同组成：卫星、雷达和地面站持续记录地球系统状态，资料同化将这些观测融合成初始场，数值模式求解动力和物理过程，集合预报进一步描述未来的不确定性。短临预报关注未来数小时的强对流和降水，中期预报覆盖未来数天至两周，次季节预测延伸到数周，气候模拟则研究外部强迫下更长时间尺度的统计响应。

近年来，人工智能逐步进入这条业务链的多个环节，多条技术路线并行发展。数据驱动模型学习历史天气场的演变规律，以更低计算成本完成全球预报；生成模型和集合学习用于描述不确定性，混合模型把神经网络与动力方程结合，资料同化模型尝试直接连接真实观测，海洋和气候模型则面向不同时间尺度的地球系统预测。本课程围绕六个专题选取 26 篇代表性论文，希望帮助我们理解 AI for Weather 研究在解决什么问题、采用了哪些关键方法，以及各条技术路线如何共同拓展地球系统预测的研究版图。

一、论文清单

1. 全球天气预报（8 篇）

序号	论文	正式出处	核心特点
1	FourCastNet —Kurth et al. <i>FourCastNet: Accelerating Global High-Resolution Weather Forecasting Using Adaptive Fourier Neural Operators</i>	<i>Proceedings of the Platform for Advanced Scientific Computing Conference</i> , Article 13, 1-11 (2023); DOI	AFNO 频域建模，高分辨率全球场快速预测
2	Pangu-Weather —Bi et al. <i>Accurate medium-range global weather forecasting with 3D neural networks</i>	<i>Nature</i> 619, 533-538 (2023); DOI	三维大气状态与分层时效预测
3	GraphCast —Lam et al. <i>Learning skillful medium-range global weather forecasting</i>	<i>Science</i> 382, 1416-1421 (2023); DOI	多尺度球面图网络
4	FuXi —Chen et al. <i>FuXi: a cascade machine learning forecasting system for 15-day global weather forecast</i>	<i>npj Climate and Atmospheric Science</i> 6, 190 (2023); DOI	短、中、长时效级联预报
5	Aurora —Bodnar et al. <i>A foundation model for the Earth system</i>	<i>Nature</i> 641, 1180-1187 (2025); DOI	跨天气、海浪与空气质量的地球系统基础模型
6	GenCast —Price et al. <i>Probabilistic weather forecasting with machine learning</i>	<i>Nature</i> 637, 84-90 (2025; 2024 年在线发表); DOI	条件扩散生成全球概率集合
7	FuXi-ENS —Zhong et al. <i>FuXi-ENS: A machine learning model for efficient and accurate ensemble weather prediction</i>	<i>Science Advances</i> 11(44), eadu2854 (2025); DOI	VAE 与流依赖扰动构造集合预报
8	WeatherNext Cyclones —Alet et al. <i>Operational Tropical Cyclone Forecasting with AI</i>	<i>Nature</i> (2026); DOI	全球场与气旋路径、强度和风圈联合概率预报

2. 短临降水预报（5 篇）

序号	论文	正式出处	核心特点
9	DGMR —Ravuri et al. <i>Skilful precipitation nowcasting using deep generative models of radar</i>	<i>Nature</i> 597, 672–677 (2021); DOI	GAN 生成多种可信雷达未来
10	EarthFormer —Gao et al. <i>Earthformer: Exploring Space-Time Transformers for Earth System Forecasting</i>	NeurIPS 35, 25390–25403 (2022); 正式页面; DOI	Cuboid Attention 时空建模
11	NowcastNet —Zhang et al. <i>Skilful nowcasting of extreme precipitation with NowcastNet</i>	<i>Nature</i> 619, 526–532 (2023); DOI	物理演变与随机生成协同预测极端降水
12	PreDiff —Gao et al. <i>PreDiff: Precipitation Nowcasting with Latent Diffusion Models</i>	NeurIPS 36, 78621–78656 (2023); 正式页面; DOI	潜空间扩散与知识对齐
13	DiffCast —Yu et al. <i>DiffCast: A Unified Framework via Residual Diffusion for Precipitation Nowcasting</i>	CVPR 2024, 27758–27767; DOI	确定性运动预测与随机残差扩散

3. 次季节预报与气候模拟（4 篇）

序号	论文	正式出处	核心特点
14	QuickClim —Kitsios, O’Kane & Newth <i>A machine learning approach to rapidly project climate responses under a multitude of net-zero emission pathways</i>	<i>Communications Earth & Environment</i> 4, 355 (2023); DOI	由排放情景转换得到的规定 CO ₂ e 浓度路径下，多变量气候响应的快速代理与重构
15	FuXi-S2S —Chen et al. <i>A machine learning model that outperforms conventional global subseasonal forecast models</i>	<i>Nature Communications</i> 15, Article 6425 (2024); DOI	42 天、51 成员次季节集合预报
16	NeuralGCM —Kochkov et al. <i>Neural general circulation models for weather and climate</i>	<i>Nature</i> 632, 1060–1066 (2024); DOI	可微动力核心与学习式物理参数化
17	UniCM —Yuan et al. <i>Learning the coupled dynamics of global climate modes</i>	<i>Nature Machine Intelligence</i> 8, 930–941 (2026); DOI	物理场与气候模态的双分支耦合

4. 海洋智能预报（3 篇）

序号	论文	正式出处	核心特点
18	OceanNet —Chattopadhyay et al. <i>OceanNet: a principled neural operator-based digital twin for regional oceans</i>	<i>Scientific Reports</i> 14, Article 21181 (2024); DOI	FNO、PEC 积分与频谱正则

序号	论文	正式出处	核心特点
19	WenHai —Y. Cui et al. <i>Forecasting the eddying ocean with a deep neural network</i>	<i>Nature Communications</i> 16, Article 2268 (2025); DOI	bulk formulae 驱动的全球上层涡旋预报
20	ORCA-DL —Guo et al. <i>Data-driven global ocean modeling for seasonal to decadal prediction</i>	<i>Science Advances</i> 11, Article eadu2488 (2025); DOI	全球三维上层海洋的月尺度预测与长期积分

5. Benchmark 与可信评估（3 篇）

序号	论文	正式出处	核心特点
21	WeatherBench 2 —Rasp et al. <i>WeatherBench 2: A Benchmark for the Next Generation of Data-Driven Global Weather Models</i>	<i>Journal of Advances in Modeling Earth Systems</i> 16(6), e2023MS004019 (2024); DOI	全球数据驱动天气预报的统一评测协议
22	ClimateBench v1.0 —Watson-Parris et al. <i>ClimateBench v1.0: A Benchmark for Data-Driven Climate Projections</i>	<i>Journal of Advances in Modeling Earth Systems</i> 14(10), e2021MS002954 (2022); DOI	数据驱动气候投影的统一任务与指标
23	极端事件评估 —Olivetti & Messori <i>Do data-driven models beat numerical models in forecasting weather extremes? A comparison of IFS HRES, Pangu-Weather, and GraphCast</i>	<i>Geoscientific Model Development</i> 17, 7915–7962 (2024); DOI	极端温度与风速的模型压力测试

6. 资料同化与分析—预报耦合（3 篇）

序号	论文	正式出处	核心特点
24	FengWu-4DVar —Xiao et al. <i>Towards a Self-contained Data-driven Global Weather Forecasting Framework</i>	ICML 2024, PMLR 235, 54255–54275; 正式页面	可微 AI 预报器嵌入 4DVar
25	FuXi-DA —Xu et al. <i>FuXi-DA: a generalized deep learning data assimilation framework for assimilating satellite observations</i>	<i>npj Climate and Atmospheric Science</i> 8, 156 (2025); DOI	卫星辐射观测与背景场的特征融合
26	LDA —Fan et al. <i>Physically consistent global atmospheric data assimilation with machine learning in latent space</i>	<i>Science Advances</i> 12(1), eaea4248 (2026); DOI	潜空间 L3DVar / L4DVar 优化

二、总体发展框架

人工智能在地球科学中的早期应用，主要集中在局地现象识别、统计降尺度和单变量预测。随着再分析资料、卫星观测和高性能计算逐步成熟，研究者开始训练能够直接推进全球大气状态的模型。2020 年前后已有全球数据驱动预报探索，2022—2023 年则出现高分辨率全球中期机器学习预报的集中突破。FourCastNet、Pangu-

Weather、GraphCast 和 FuXi 从频域算子、三维大气结构、球面图计算和分时效级联等方向展示了全球机器学习预报的潜力。

随着全球预测能力提升，相关研究也在多个方向上并行推进。GenCast 和 FuXi-ENS 将概率建模融入训练，提升集合预报质量；WeatherNext Cyclones 将全球预报进一步连接到热带气旋危险度预测。NowcastNet、PreDiff 和 DiffCast 分别从物理约束、潜空间扩散和残差分解改进短临降水预报；NeuralGCM、WenHai、ORCA-DL 和 UniCM 则探索混合动力、海洋和气候尺度上的建模。与此同时，FengWu-4DVar、FuXi-DA 和 LDA 开始处理初始场问题。WeatherBench 2、ClimateBench 和极端事件评估分别为全球天气、气候代理和极端事件任务建立可复现的评测坐标。

当前研究已形成覆盖观测、分析、预报、集合生成和评估等环节的研究版图。我们可以用六个关键词把握这一过程：**全球场建模、概率化、物理融合、跨尺度、观测驱动和可信评估**。这些方向相互交叉，也共同决定 AI 能否真正进入地球系统预报流程。

三、专题一：全球天气预报

全球天气预报根据某一时刻的全球大气状态，预测未来数天至两周的大气演变。模型需要同时处理不同高度上的温度、风、湿度和气压，并刻画天气系统在全球范围内的传播。随着预报时效增加，初始误差会迅速放大，因此中期预报既考验模型的空间表示能力，也考验长期滚动的稳定性。

本课程所选的早期全球机器学习天气模型以确定性预报器为主体，用神经网络直接学习全球天气场的时间演变。FourCastNet、Pangu-Weather、GraphCast 和 FuXi 分别探索频域算子、三维结构、球面图和分时效级联，其中 Pangu-Weather 和 FuXi 已开展扰动集合实验。GenCast 和 FuXi-ENS 进一步将概率建模与集合质量纳入模型训练，全球概率预报也随之拓展到热带气旋等高影响天气。




图 1. 全球天气预报模型由确定性预测走向概率集合。FuXi 延伸出 FuXi-ENS，GraphCast 的球面网格路线发展出 GenCast，GenCast 又进一步连接到热带气旋路径、强度和风圈的联合预测。Aurora 代表跨任务的地球系统基础模型路线。

3.1 确定性预报器首先改变计算方式

FourCastNet 将天气预报表述为高维场到场映射，利用 AFNO 在频域混合全球信息，从而兼顾计算吞吐量与全局感受野。它展示了学习式算子快速推进高分辨率全球天气场的可行性。

Pangu-Weather、**GraphCast** 与 **FuXi** 从三个方向改进全球预报。**Pangu-Weather** 将气压层和地表变量组织为三维状态，并用不同时间步长的模型控制误差增长；**GraphCast** 把规则经纬网格映射到多尺度球面图，在局地更新与全球传播之间建立联系；**FuXi** 按短、中、长时效训练级联模型，让每个阶段适应相应的误差分布。这几项工作共同构成确定性全球 AI 预报的早期主干。

3.2 基础模型扩展任务边界

Aurora 将多个地球系统任务纳入共享表征框架。模型先从异质地球数据中学习通用表征，再适配天气、空气质量和海浪等具体任务。它把研究重点从单一预报器推进到可迁移的地球系统基础模型。

3.3 概率集合扩展不确定性表达与高影响天气危险度预报

GenCast 用条件扩散生成多个全球天气轨迹，使集合同时保持空间细节并表达与初始状态相符的不确定性。它延续 **GraphCast** 的球面 grid-mesh 建模路线，并将核心处理器发展为球面网格上的 graph transformer。**FuXi-ENS** 采用 VAE、流依赖扰动和概率损失构建另一条集合预报路线。前者强调扩散生成与联合分布，后者更关注集合生成效率、扰动设计和概率校准。

WeatherNext Cyclones 沿用与 **GenCast** 相近的总体架构，在每个预报时间步以单次前向随机生成替代多步扩散去噪，联合输出全球天气状态以及气旋位置、强度和风圈变量，再通过自回归滚动生成多日集合预报。大规模集合可为气旋路径偏转、快速增强和风圈危险度提供概率信息。

本专题要点

全球 AI 天气预报已经从单一确定性轨迹扩展到概率集合和高影响天气概率产品。模型关注的对象也从全球气象变量，进一步延伸到热带气旋等高影响事件。从确定性预报器到直接概率建模，变化的不只是输出数量，还包括训练目标和预报质量的衡量方式。我们可以沿着全球场表示、集合生成和跨任务迁移三条线索，理解不同模型的设计取舍。

讨论与思考

- 频域算子、三维 Transformer、球面图和级联模型分别在解决哪一种误差来源？
- 概率模型的价值应由平均误差、集合离散度、校准还是极端事件收益来衡量？
- 基础模型的共享表征何时有助于天气预报，何时可能掩盖任务特异性？

四、专题二：短临降水预报

短临降水预报通常面向未来 0-6 小时，主要依据连续雷达回波预测降水系统的移动、增强、减弱和消散。平流运动相对容易追踪，强对流的突然生成和快速发展却具有很强的不确定性。准确预报这些变化，直接关系到城市内涝、山洪和强对流天气预警。

早期深度学习方法把雷达外推视为确定性视频预测，常常得到过于平滑的结果。**DGMR** 用生成模型产生多种可信未来，**EarthFormer** 改进通用时空表示；随后，**NowcastNet** 把物理演变过程引入生成模型，**PreDiff** 和 **DiffCast** 则沿不同的扩散建模路线处理随机演变。这个领域由此形成两条主线：一条改进时空架构，另一条重新分配数据驱动、物理约束和概率生成的作用。

Nowcasting Models




图 2. 左侧比较三种时空建模方式: EarthFormer 进行确定性预测, PreDiff 使用潜空间扩散, DiffCast 结合确定性预测与残差扩散, 并采用联合端到端训练。右侧展示从数据生成到物理引导的变化: DGMR 学习雷达序列分布, NowcastNet 在生成过程中加入可微物理演变。

4.1 从单一确定性预测到多种未来情景

DGMR 根据同一段历史雷达序列生成多个未来情景, 并通过判别机制约束空间真实性和时间一致性。它缓解了像素平均造成的模糊问题, 也把短临预报的评价范围扩展到感知质量、降水统计和专家判断。

EarthFormer 提出的 Cuboid Attention 面向通用时空预测。它将大规模时空张量划分为多个立方体, 在局部注意力之外引入全局向量, 从而兼顾局地细节和远距离信息交换。PreDiff 基于 Earthformer 的 Cuboid Attention 构建去噪骨干 Earthformer-UNet, 在潜空间中进行条件扩散。

4.2 物理引导与扩散模型分化为两条路线

NowcastNet 先用确定性演变网络预测运动场和强度变化, 再通过可微演变算子得到粗尺度降水演变; 随后, 随机生成网络结合历史雷达、物理演变结果和随机噪声, 补充公里尺度的对流细节。模型把大尺度运动和小尺度生成分开处理, 使物理过程与随机性各自承担清晰的任务。

PreDiff 在潜空间运行扩散过程, 并用 Knowledge Alignment 调整各步去噪的转移分布。另一条独立路线中, **DiffCast** 将未来降水分解为确定性部分和随机残差: 确定性骨干先得确定性基准预测 μ , 条件扩散模型再生成残差 $\hat{r}$, 最终输出 $\hat{y} = \mu + \hat{r}$ 。这种分解使模型能够分别学习稳定运动与随机对流变化。

本专题要点

短临降水预报正在从“预测一张未来雷达图”转向“描述一组可能的对流演变”。模型需要同时保持运动连续性、局地强度和概率多样性。时空架构决定模型如何组织降水运动信息, 物理约束和概率生成则帮助刻画强度变化与随机细节。理解这些部分如何分工, 有助于把握不同方法处理强对流演变的思路。

讨论与思考

- DGMR 的多样性、NowcastNet 的物理分工和 DiffCast 的残差分解, 分别对应怎样的不确定性假设?
- 领域知识应进入输入、网络结构、生成引导还是评价指标?
- 对极端降水而言, 视觉真实性与预警价值可能在哪些情况下不一致?

五、专题三：次季节预报与气候模拟

次季节预报关注未来两周到两个月的大气变化，试图从快速衰减的天气可预报性中提取较慢的信号，例如季风、MJO 和海气耦合模态。气候模拟与投影则更关注多年统计特征，以及温室气体等外部强迫如何改变气候系统。两类问题都面向长时间尺度，但前者以初始状态为起点，后者更强调外部强迫和统计响应。

AI 在这一尺度上形成了多种任务形态。FuXi-S2S 直接生成 42 天集合预报；QuickClim 根据由排放情景转换得到的规定 CO_2e 浓度路径，快速代理并重构多变量气候响应；NeuralGCM 将可微动力核心与学习式物理参数化结合；UniCM 则聚焦 ENSO 等气候模态之间的耦合。我们需要根据输入信息、输出对象和评价目标来理解这些工作。




图 3. 四张卡片分别呈现气候响应代理、次季节集合、混合动力模型和气候模态预测。QuickClim 面向由排放情景转换得到的规定 CO_2e 浓度路径，FuXi-S2S 从初始场生成 42 天集合，NeuralGCM 在高维全球大气场上结合动力核心与学习式物理，UniCM 通过物理场与气候模态的双分支耦合进行联合预测。

5.1 情景代理：快速扩展可探索路径

QuickClim 将由净零排放情景转换得到的规定 CO_2e 浓度路径映射为气候响应，再通过 FEM-BV-VARX、EOF 空间重构和变率采样生成多变量网格场。它把计算成本较高的情景模拟转化为快速代理，为比较大量浓度路径提供工具。ClimateBench 则从统一任务和指标的角度评估这类气候代理模型。

5.2 次季节集合：寻找仍可预报的低频成分

FuXi-S2S 将机器学习集合预报延伸到 42 天，并通过流依赖的潜空间高斯扰动构造 51 个集成员。论文重点检验降水、向外长波辐射和 MJO 等低频信号，展示了 AI 模型捕捉部分次季节可预报成分的能力。

5.3 高维全球大气场上的混合动力模型

NeuralGCM 保留可微分大气动力核心，并用神经网络表示单柱物理过程。动力核心负责可解析的大尺度演变，学习式参数化处理复杂的次网格过程。论文评估了确定性天气预报、随机集合预报以及以确定性配置为主的长期气候模拟，体现了 AI 与数值动力框架的深度结合。长期气候实验主要在规定海表温度和海冰条件下进行，因此不能直接等同于完全耦合海气未来气候投影。

5.4 物理场与气候模态的联合预测

UniCM 用 Globalformer 学习海温、风应力等物理场的演变，用 Modeformer 学习 ENSO 等七类气候模态及其相互作用，再将模态表征注入物理场分支，联合预测物理场与气候模态。

本专题要点

时间尺度越长，研究对象越从瞬时天气场转向低频信号、集合分布和气候统计。AI 模型需要根据任务重新选择状态表示和评价指标。次季节预报从初始状态中寻找可持续数周的信号，气候投影则关注给定外部强迫下的统计响应。理解两类任务的信息来源，有助于把握直接预测、混合动力和气候代理各自的建模思路。

讨论与思考

- 天气预报、次季节预报和气候模拟的“准确”是否应使用同一套定义？
- NeuralGCM 的混合结构与纯数据驱动模型相比，在哪些场景更有优势？
- 气候模态预测中的注意力或耦合结构能否被解释为动力机制证据？

六、专题四：海洋智能预报

海洋储存并输送大量热量、动量和物质，对天气和气候具有持续影响。海洋预报需要估计海表高度、温度、盐度和流速等变量，同时处理涡旋、边界流、海气交换和稀疏观测。与大气相比，海洋演变更慢、记忆更长，三维观测也更有限，因此模型既要刻画局地涡旋，又要保持长期积分的稳定性。

当前海洋 AI 模型沿着不同空间和时间尺度展开。OceanNet 聚焦区域海表高度，WenHai 预测全球上层涡旋海洋，ORCA-DL 则面向月尺度全球三维上层海洋。三项工作分别探索神经算子、显式大气强迫和多变量时序融合，构成海洋智能预报的代表性任务空间。




图 4. 三张卡片分别概括区域海表高度预测、全球上层涡旋预报和全球三维上层海洋预测。OceanNet 组合 FNO、PEC 积分和频谱正则；WenHai 将 bulk formulae 计算的通量与数值天气预报提供的辐射、降水信息组合为八个海气强迫通道；ORCA-DL 以海洋状态和大气风应力为输入，通过变量专属编码器和 Time-Rotary Fusion 预测海洋的月尺度演变。

6.1 区域海洋数字孪生

OceanNet 用 Fourier Neural Operator 学习西北大西洋西边界流系统的海表高度演变，重点包括 Gulf Stream 和 Gulf of Mexico 等区域。Predictor-Evaluate-Corrector 通过多次调用 FNO 完成时间积分，spectral regularizer 负责约束预测场的频谱结构。模型由此兼顾计算效率与中尺度涡旋的空间细节。

6.2 全球涡旋海洋预报

WenHai 将海表高度、温度、盐度和流速等上层海洋状态与海气动量、热量和淡水通量结合，形成 1/12°、逐日、1-10 天的全球涡旋预报。模型先用 bulk formulae 把近地面大气和海表状态转换为海气通量，再与辐射、降水共同组成八个强迫通道，最后由 Swin Transformer 预测 0-643 m 上层海洋的状态增量。大气强迫在这里直接参与海洋演变计算。

6.3 全球三维月尺度上层海洋预报／模拟

ORCA-DL 以当前海洋变量、风应力、海陆掩膜和 lead time Δt 为输入，经变量专属 ocean encoders、atmosphere encoder、Time-Rotary Fusion 和变量专属 decoders 输出 $O(t + \Delta t)$ 。模型采用月尺度直接预测和自回归滚动，并通过 10 成员集合表征模型与预测不确定性。十年积分主要用于检验长期稳定性和历史气候态再现，不能据此认为模型已经验证了变化外部强迫下的未来气候投影。

本专题要点

海洋智能预报的关键，是在局地涡旋细节、三维结构、海气强迫和长期稳定性之间取得平衡。不同模型选择了不同的空间范围和时间步长，也对应不同的科学问题。大气强迫将动量、热量和淡水交换引入海洋预测，多变量建模则刻画温度、盐度和流速之间的联系。阅读时可重点比较模型如何表示海洋内部演变，以及如何接收海气界面的外部驱动。

讨论与思考

- 区域边界条件会如何影响 FNO 海洋数字孪生的预测结果？
- 海气通量作为输入与显式耦合大气模型有何差异？
- 长期稳定积分应怎样区分“数值不发散”和“气候统计可信”？

七、专题五：Benchmark 与可信评估

只有在数据、初始化、变量定义、预报时效、空间重网格、气候态基准和评价指标尽可能一致时，模型比较才具有较强可解释性。天气预报还具有明显的区域、变量和时效差异：一个模型可能在全球平均误差上表现很好，却在局地强风或极端高温上失去优势。因此，Benchmark 既要建立统一评测协议，也要把平均技巧扩展到概率质量和极端事件。

ClimateBench 和 WeatherBench 2 分别服务于气候响应代理和全球天气预报，极端事件评估则把模型放到高影响场景中检验。它们分别为气候代理、全球天气和极端事件任务建立可复现的评测坐标，推动研究从“展示一个更低误差”走向面向具体任务的可比较评价。

7.1 两条并行 Benchmark 分支

ClimateBench v1.0 统一外部强迫、目标气候变量、训练与测试场景以及评价指标，使数据驱动气候代理模型能够在共同设置下比较。它关注的是外部强迫到气候响应的映射。

WeatherBench 2 为全球中期天气预报提供统一数据、基线和接近业务检验的评分协议。研究者可以在一致的变量、预报时效和空间聚合设置下比较 Pangu-Weather、GraphCast 和 GenCast 等模型，并追踪数据处理与评测实现带来的差异。

7.2 从平均技巧到极端事件压力测试

Olivetti 与 Messori 比较 IFS HRES、Pangu-Weather 和 GraphCast 在近地面温度与风速极端上的表现，并按区域、事件和时效拆分结果。这项工作说明，平均 RMSE 只能概括总体误差，高影响天气还需要检验尾部分布、阈值事件和区域差异。

本专题要点

Benchmark 决定我们如何理解模型进步。统一数据和指标解决“能否公平比较”，极端事件评估进一步回答“模型是否真正改善了高影响天气预报”。阅读评测结果时，应把变量、区域和预报时效与指标一起考察，理解模型优势出现在哪些条件下。确定性误差、概率校准和极端事件表现共同构成对预报能力的多维评价。

讨论与思考

- Benchmark 的数据、基线、指标和实现代码中，哪一部分最容易改变结论？
- 确定性模型与概率集合模型是否可以使用同一套排行榜？
- 极端事件评估应以阈值、重现期、对象识别还是决策损失为中心？

八、专题六：资料同化与分析—预报耦合

天气预报首先需要知道大气“现在是什么状态”。卫星、雷达、地面站和探空观测在时间、空间和变量上分布不均，还包含不同来源的误差。资料同化将这些观测与短时背景预报结合，生成结构完整、动力协调的分析场，再用它启动下一次预报。

AI 预报模型早期大多直接使用 ERA5 等现成分析场，因此模型训练与真实观测之间仍隔着资料同化环节。FengWu-4DVar、FuXi-DA 和 LDA 分别从模型空间、特征空间和潜空间处理这一问题，代表可微变分、监督融合和潜空间优化三种路线。




图 5. 资料同化位于观测与预报之间：背景场和观测共同生成分析场，分析场再初始化后续预报。FengWu-4DVar 在模型空间执行 4DVar，FuXi-DA 在特征空间融合卫星辐射观测，LDA 则在潜空间完成变分优化。

8.1 模型空间中的可微变分同化

FengWu-4DVar 将 FengWu 预报模型嵌入四维变分目标，通过自动微分计算梯度，并用球谐变换近似背景误差的水平相关。预报模型在同化窗内传播大气状态，观测失配则不断修正初始场。它展示了可微 AI 预报器如何承担 4DVar 中的动力约束。论文的一年循环实验主要基于 ERA5 构造的模拟观测。

8.2 面向真实卫星资料的直接融合

FuXi-DA 分别编码 FY-4B/AGRI 卫星辐射观测和 FuXi 背景场，在特征空间融合后生成分析场，再由固定的 FuXi 预报器提供 6-60 小时预报监督。模型通过后续预报质量反向约束分析场，使观测融合直接服务于天气预报。论文直接使用真实 FY-4B/AGRI 卫星资料，但未进行长期循环同化验证。

8.3 潜空间中的变分同化

LDA 先用编码器学习多变量全球大气的潜在表示，再在潜空间中执行 L3DVar 或 L4DVar。解码器 D 将潜变量还原为物理场，L3DVar 通过观测算子 H 计算观测失配 $y - H(D(z))$ ；L4DVar 则调用预报模型 $M_{0 \rightarrow i}$ ，计算同化窗内各时刻的观测失配 $y_i - H(M_{0 \rightarrow i}(D(z)))$ 。潜空间压缩了优化维度，同时保留多变量之间的结构关系。

本专题要点

资料同化把 AI 天气模型与真实观测连接起来。核心问题包括如何表示背景误差和观测误差，如何利用预报模型传播信息，以及如何保持分析场中的多变量协调关系。三条路线的主要差异，在于把观测约束施加在物理状态、学习特征还是潜在表示上。分析场质量及其带来的后续预报改进，是理解这些同化方法效果的两条重要线索。

讨论与思考

- 可微 4DVar、监督式特征融合和潜空间变分优化分别保留了哪些传统同化概念？
- 模拟观测、真实卫星观测和长期循环实验分别如何评价同化系统？
- 潜空间中的“物理一致性”应通过平衡关系、守恒量还是后续预报技巧验证？

九、建议阅读顺序

建议按四个层次推进：

1. **全球确定性预报**。阅读 FourCastNet、Pangu-Weather、GraphCast、FuXi 和 Aurora，比较全球状态表示与任务扩展方式。
2. **概率预报与短临降水**。先读 GenCast、FuXi-ENS 和 WeatherNext Cyclones，再按 DGMR $\rightarrow$ EarthFormer $\rightarrow$ PreDiff 理解从生成式情景到时空表示和潜空间扩散的演进，并将 NowcastNet 和 DiffCast 作为不同方法路线对照阅读。
3. **长时效与海洋**。用 FuXi-S2S、QuickClim、NeuralGCM 和 UniCM 理解次季节与气候任务，再通过 OceanNet、WenHai 和 ORCA-DL 认识海洋预报。
4. **评估与资料同化**。最后阅读 WeatherBench 2、ClimateBench、极端事件评估、FengWu-4DVar、FuXi-DA 和 LDA，补全从观测到检验的预报链条。

十、结语

AI for Weather 正从单项模型扩展到覆盖预报系统多个环节的组件与研究框架。全球与短临预测、概率集合、海洋与气候建模、资料同化和评估正在形成相互关联但尚未完全打通的地球系统预测研究版图；概率表达、物理融合、观测接入与极端事件检验将塑造下一阶段。